Ranking Classification Pipelines with Statistical Dataset Embeddings: A Meta-Learning Approach

J. V. Dos Santos Gomes, J. Aikes Junior, D. Pereira dos Santos

Universidade Tecnológica Federal do Paraná (UTFPR), Brazil
joaogomes.2003@alunos.utfpr.edu.br, jorgejunior@utfpr.edu.br, davip@professores.utfpr.edu.br

Abstract. Selecting an adequate machine learning pipeline – the combination of preprocessing operators and a classification algorithm – is a central problem in Automated Machine Learning (AutoML), since model performance depends critically on this choice and no single configuration is universally superior. This work proposes and evaluates a meta-learning approach that ranks and recommends classification pipelines for a previously unseen dataset using statistical embeddings. A meta-dataset is built by systematically running 60 pipelines, combining four scaling operators, three feature selectors and five classifiers, over 201 datasets from OpenML, evaluated through 5-fold stratified cross-validation, yielding a 201×60 matrix of balanced-accuracy scores. Each dataset is represented by a 64-dimensional distributional statistical embedding inspired by Dataset2Vec, which summarizes the per-attribute distribution of meta-features in a schema-agnostic way. A multi-output k-nearest neighbors (k-NN) predictor is then trained on these embeddings and evaluated by Leave-One-Out at the dataset level, using Spearman and Kendall rank correlations, the weighted Kendall tau (which penalizes errors at the top of the ranking more heavily) and NDCG. For $k = 10$, the predictor achieves mean Spearman, Kendall and weighted-Kendall correlations of 0.58, 0.48 and 0.52, respectively, clearly outperforming random and global-mean baselines and matching the range reported by comparable approaches in the literature. A statistical analysis further shows that several embedding dimensions correlate significantly ($p < 0.0001$) with ranking quality. These results indicate that simple, reproducible statistical embeddings combined with an instance-based predictor already provide a competitive baseline for pipeline ranking, opening a path toward neural embeddings such as Dataset2Vec.

CCS Concepts: • **Computing methodologies** → **Machine learning algorithms**; *Learning latent representations*; • **Information systems** → *Learning to rank*.

Keywords: AutoML, dataset embeddings, k-nearest neighbors, meta-learning, pipeline ranking

1. INTRODUÇÃO

A escolha do algoritmo mais adequado para um problema de aprendizado de máquina é um dos maiores desafios enfrentados por profissionais da área, já que nenhum algoritmo é universalmente superior em todos os domínios – fato formalizado pelo teorema *No Free Lunch* [Wolpert and Macready 1997]. Construir um pipeline eficiente exige ainda uma combinação cuidadosa de representação, avaliação e otimização [Domingos 2017], processo que tradicionalmente depende fortemente da expertise humana e de tentativa e erro.

O *Automated Machine Learning* (AutoML) busca reduzir esse esforço automatizando a seleção de algoritmos e o ajuste de hiperparâmetros, e sua eficácia aumenta substancialmente quando combinado a técnicas de *meta-aprendizado* [Schoenfeld 2020; Vanschoren 2018]: ao extrair meta-características que resumem propriedades estatísticas, estruturais e informacionais dos conjuntos de dados, um meta-modelo pode aprender, a partir da experiência acumulada, quais configurações tendem a ter sucesso

Copyright©2025 Permission to copy without fee all or part of the material printed in KDMiLe is granted provided that the copies are not made or distributed for commercial advantage, and that notice is given that copying is by permission of the Sociedade Brasileira de Computação.

em problemas semelhantes [Schoenfeld et al. 2022].

Entretanto, boa parte da literatura de AutoML e meta-aprendizado concentra-se na seleção do modelo e no ajuste de hiperparâmetros, desconsiderando o impacto do *pré-processamento dos dados*. Escalonamento inadequado, seleção de atributos prejudicial ou tratamento pobre de variáveis categóricas podem comprometer todo o pipeline, independentemente da qualidade do classificador final. Além disso, a maioria dos sistemas de recomendação reduz o problema à escolha de uma única melhor configuração (top-1), descartando a informação ordinal que um ranking completo oferece – exatamente a informação mais útil para um usuário que deseja inspecionar uma lista curta de candidatos.

Este trabalho aborda essas duas lacunas propondo uma abordagem de meta-aprendizado que (i) trata escalonamento, seleção de atributos e classificação como um único pipeline integrado, e (ii) formula a recomendação como um problema de *ranqueamento*, e não de seleção top-1, introduzindo ainda o Kendall Tau *ponderado* como métrica de avaliação que reflete mais diretamente a utilidade prática de um ranking ao penalizar com mais peso os erros próximos ao topo. Concretamente, nós (a) construímos um meta-conjunto a partir da execução sistemática de 60 pipelines de classificação sobre 201 datasets do OpenML [Vanschoren et al. 2014], representando cada dataset por um embedding estatístico distribucional de 64 dimensões, e (b) treinamos e avaliamos, por meio de validação *Leave-One-Out* (LOO) no nível de datasets, um preditor k-vizinhos-mais-próximos (k-NN) multi-saída que estima o ranking de desempenho esperado dos 60 pipelines para um dataset inédito. O meta-conjunto resultante – 201 datasets e 60 pipelines avaliados por validação cruzada estratificada – constitui, por si só, uma contribuição empírica de escala comparável ou superior à da maioria dos estudos da área [Vanschoren 2018].

O restante deste artigo está organizado da seguinte forma. A Seção 2 situa este trabalho frente a abordagens de representação de datasets e recomendação de pipelines. A Seção 3 descreve a metodologia em duas fases (construção do meta-conjunto e meta-aprendizado por ranqueamento). A Seção 4 apresenta e discute os resultados experimentais, e a Seção 5 conclui o trabalho e aponta direções futuras.

2. TRABALHOS RELACIONADOS

Os trabalhos relevantes para esta pesquisa podem ser organizados em três eixos: (i) representação de datasets por meta-características e embeddings, (ii) recomendação de algoritmos e pipelines via meta-aprendizado, e (iii) avaliação de recomendações baseada em ranqueamento.

Quanto à representação, conjuntos clássicos de meta-características descrevem datasets por meio de um vetor fixo de descritores estatísticos, informacionais e baseados em modelos, enquanto abordagens mais recentes aprendem embeddings densos diretamente dos dados. Jomaa et al. [2021] propõem o Dataset2Vec, uma arquitetura neural que aprende representações de datasets agnósticas ao esquema, amostrando e agregando estatísticas por atributo por meio de codificadores de conjuntos hierárquicos; o embedding distribucional adotado neste trabalho é diretamente inspirado nessa ideia, mas substitui o codificador aprendido por agregações estatísticas pré-definidas, trocando poder representacional por simplicidade, interpretabilidade e reprodutibilidade.

Quanto à recomendação, Schoenfeld et al. [2022] mostram que ranquear pipelines pela similaridade das meta-características dos datasets produz recomendações melhores do que estimar diretamente o desempenho absoluto, e que representar pipelines de forma estruturada (em vez de rótulos opacos) melhora o meta-aprendizado. Schoenfeld [2020] estende essa linha explorando metadados granulares de pipelines. Esses trabalhos, contudo, em geral avaliam rankings com métricas – como correlação de Spearman ou acurácia top-k – que não diferenciam erros no topo do ranking de erros nas posições inferiores, ainda que os primeiros sejam muito mais custosos na prática, já que usuários tipicamente inspecionam apenas os primeiros pipelines recomendados.

Este trabalho se diferencia ao (i) avaliar pipelines como combinações completas de escalonamento, seleção e classificação, em vez de componentes isolados; (ii) adotar o ranqueamento, e não a seleção top-1, como paradigma de recomendação; e (iii) introduzir o Kendall Tau ponderado [Virtanen et al. 2020] como métrica de avaliação que recompensa diretamente o ordenamento correto dos melhores pipelines. Além disso, fornece um meta-conjunto de tamanho considerável e abertamente reprodutível (201 datasets × 60 pipelines, avaliados por validação cruzada estratificada de 5 folds), que pode servir como benchmark para futuros estudos de meta-aprendizado na comunidade de AutoML [Vanschoren 2018].

3. METODOLOGIA

A metodologia experimental está organizada em duas fases: (1) construção de um meta-conjunto que associa embeddings de datasets a rótulos de desempenho de pipelines, e (2) treinamento e avaliação de um metamodelo de ranqueamento sobre esse meta-conjunto.

3.1 Fase 1 – Construção do Meta-conjunto

Datasets. Foram selecionados 201 datasets de classificação do repositório OpenML [Vanschoren et al. 2014], filtrando-se tarefas com 500 a 10 mil instâncias, ao menos duas classes e atributos predominantemente numéricos, de modo que os mesmos operadores de pré-processamento pudessem ser aplicados uniformemente. De 243 identificadores de tarefas candidatos, 201 datasets foram carregados com sucesso e atenderam aos critérios de qualidade; os 42 restantes foram descartados por falha no download ou por problemas de qualidade.

Arsenal de pipelines. Sessenta pipelines foram definidos como o produto cartesiano de quatro operadores de escalonamento (incluindo a opção identidade, sem escalonamento), três estratégias de seleção de atributos (incluindo nenhuma seleção) e cinco algoritmos de classificação (Random Forest, SVM, k-NN, entre outros usados como aprendizes-base no estudo original), totalizando $4 \times 3 \times 5 = 60$ configurações. Cada pipeline foi avaliado em cada dataset por validação cruzada estratificada de 5 folds, e seu desempenho foi resumido pela acurácia balanceada

$$\mathrm{BA} = \frac{1}{C} \sum_{c=1}^{C} \frac{TP_c}{TP_c + FN_c}, \tag{1}$$

em que C é o número de classes, e TP_c e FN_c são, respectivamente, os verdadeiros positivos e falsos negativos da classe c. Essa métrica é robusta ao desbalanceamento de classes, comum entre os datasets selecionados. A execução dos 60 pipelines sobre os 201 datasets produziu 12.060 avaliações pipeline-dataset (com 172 valores ausentes causados por falhas pontuais de execução), organizadas em uma matriz de desempenho $Y \in \mathbb{R}^{201 \times 60}$.

Embeddings de datasets. Cada dataset é ainda representado por um vetor numérico de tamanho fixo que resume suas propriedades estatísticas de forma agnóstica ao esquema – isto é, independentemente do número de atributos ou instâncias –, seguindo o espírito do Dataset2Vec [Jomaa et al. 2021]. Para cada atributo, calcula-se um conjunto de meta-características (por exemplo, medidas de tendência central, dispersão, assimetria e conteúdo informacional), e a distribuição empírica de cada meta-característica *entre os atributos* é resumida em um número fixo de estatísticas (como média, desvio-padrão e quantis), formando um bloco distribucional de 45 dimensões. Um bloco global complementar de 10 dimensões captura propriedades do dataset como um todo (número de instâncias, número de atributos, número de classes, balanceamento de classes etc.). A concatenação é truncada ou preenchida com zeros até um comprimento fixo de 64, produzindo a matriz de embeddings $X \in \mathbb{R}^{201 \times 64}$. O par (X, Y) constitui o meta-conjunto utilizado na Fase 2.

3.2 Fase 2 – Preditor de Ranking de Pipelines

Preditor. Dado o embedding D_{new} de um novo dataset, estima-se a acurácia balanceada esperada de cada pipeline P_j pela média dos rótulos de seus k vizinhos mais próximos no espaço de embeddings (utilizando uma KD-Tree para busca eficiente):

$$\hat{A}(P_j) = \frac{1}{k} \sum_{D_i \in \mathcal{N}_k(D_{new})} A_{i,j}, \tag{2}$$

em que $\mathcal{N}_k(D_{new})$ é o conjunto dos k vizinhos mais próximos de D_{new} (por distância euclidiana no espaço de embeddings) e $A_{i,j}$ é a acurácia balanceada do pipeline P_j no dataset D_i (ou seja, a entrada $Y_{i,j}$). Ordenando as 60 estimativas $\hat{A}(P_1), \ldots, \hat{A}(P_{60})$ em ordem decrescente, obtém-se o ranking previsto para D_{new}. Esse preditor simples, multi-saída e baseado em instâncias foi escolhido deliberadamente como uma baseline interpretável e computacionalmente leve: cada predição pode ser rastreada até um pequeno conjunto de datasets similares já observados.

Protocolo de validação. O preditor é avaliado por *Leave-One-Out* (LOO) no nível de *datasets*: cada um dos 201 datasets é, por sua vez, retido como consulta, enquanto os 200 restantes formam o conjunto de vizinhos; o ranking previsto é então comparado ao ranking real (obtido ordenando os rótulos verdadeiros de acurácia balanceada $Y_{i,\cdot}$). Esse protocolo é repetido para $k \in \{1, 3, 5, 7, 10\}$, a fim de estudar a sensibilidade do preditor ao tamanho da vizinhança.

Métricas de ranqueamento. Quatro métricas complementares são usadas para comparar os rankings previsto e real de cada dataset retido: a correlação de postos de Spearman; o Kendall Tau padrão,

$$\tau = \frac{P - Q}{\binom{n}{2}}, \tag{3}$$

em que P e Q são, respectivamente, os números de pares concordantes e discordantes entre os $n = 60$ pipelines; o Kendall Tau *ponderado* τ_w (`scipy.stats.weightedtau` [Virtanen et al. 2020]), que atribui pesos maiores às inversões de ordem ocorridas próximas ao topo do ranking real – isto é, entre os melhores pipelines –, penalizando mais severamente os erros de maior impacto prático; e o *Normalized Discounted Cumulative Gain*,

$$\mathrm{NDCG} = \frac{\mathrm{DCG}}{\mathrm{IDCG}}, \quad \mathrm{DCG} = \sum_{i=1}^{n} \frac{2^{rel_i} - 1}{\log_2(i+1)}, \tag{4}$$

em que rel_i é a relevância (acurácia balanceada real) do pipeline colocado na posição i pelo ranking *previsto*, e IDCG é o DCG do ranking ideal; NDCG $= 1$ indica um ranking perfeito, e valores próximos de 1 indicam que os pipelines realmente melhores estão posicionados perto do topo.

Como análise complementar, mede-se, para cada uma das 64 dimensões d do embedding, a correlação de Spearman entre os escores de Kendall ponderado por dataset $\{\tau_w^{(i)}\}_{i=1}^{201}$ e os respectivos valores de embedding $\{x_d^{(i)}\}_{i=1}^{201}$, a fim de identificar quais aspectos da representação do dataset são mais preditivos da qualidade do ranqueamento, fornecendo alguma interpretabilidade ao sistema proposto.

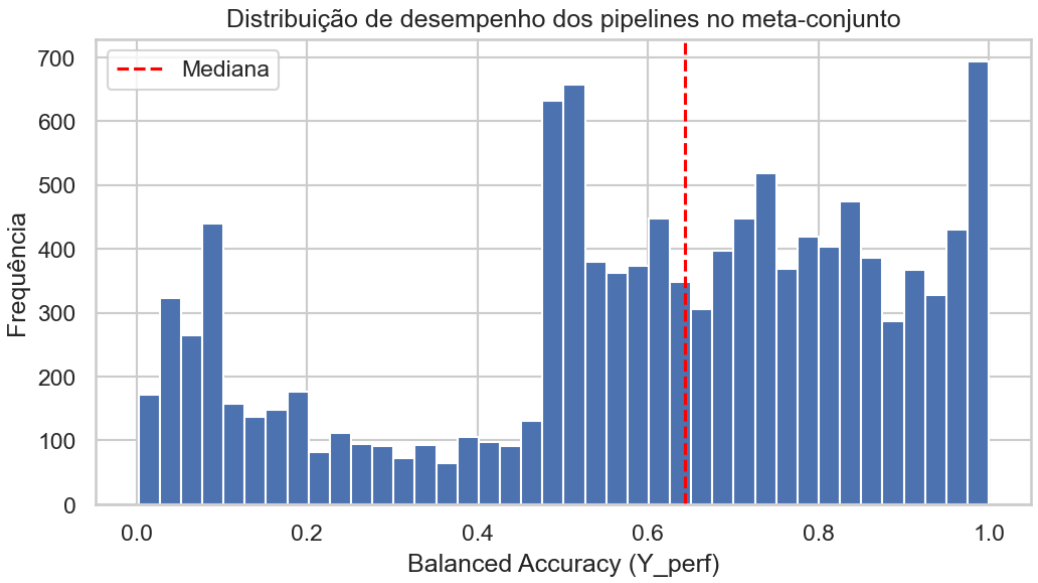


Fig. 1. Distribuição (bimodal) dos escores de acurácia balanceada no meta-conjunto, com mediana indicada pela linha tracejada.

4. RESULTADOS E DISCUSSÃO

4.1 Caracterização do Meta-conjunto

O meta-conjunto construído compreende uma matriz de embeddings $X \in \mathbb{R}^{201\times64}$ e uma matriz de desempenho $Y \in \mathbb{R}^{201\times60}$ com 12.060 entradas (172 ausentes). A Figura 1 mostra que a distribuição dos escores de acurácia balanceada é bimodal, com mediana em torno de 0,63, indicando que o desempenho dos pipelines varia substancialmente entre as combinações de dataset e configuração – exatamente a variabilidade que um recomendador baseado em ranking precisa capturar. Uma análise por componente do arsenal de pipelines mostra que a escolha do classificador domina o desempenho geral (Random Forest tem, em média, o melhor desempenho), que a escolha do escalador tem impacto comparativamente baixo e que, de forma um tanto contraintuitiva, não aplicar seleção de atributos supera, em média, a seleção via PCA ou SelectKBest em cerca de 3,5 pontos percentuais – sugerindo que, para os datasets considerados, a redução de atributos descarta sinal útil com mais frequência do que remove ruído. Uma projeção UMAP bidimensional do espaço de embeddings, somada a uma análise de similaridade de cosseno, mostra que datasets com perfis estatísticos semelhantes tendem a se agrupar e a compartilhar padrões de desempenho de pipelines parecidos – a propriedade estrutural explorada pelo preditor k-NN da Fase 2.

4.2 Avaliação do Preditor de Ranking

A Tabela I resume a avaliação LOO para $k \in \{1, 3, 5, 7, 10\}$ (média ± desvio-padrão sobre os folds válidos), e a Figura 2 ilustra a evolução das correlações de Spearman e Kendall em função de k. O desempenho melhora monotonicamente com k até $k = 10$ (maior valor testado), o que atribuímos ao efeito de suavização da média na Eq. (2), que reduz a variância da estimativa à medida que mais vizinhos são agregados. Para $k = 10$, com 198 folds válidos (3 datasets foram excluídos por rótulos ausentes), o preditor atinge correlação de Spearman média de 0,58±0,36, Kendall padrão de 0,48±0,34, Kendall ponderado de $0{,}52 \pm 0{,}35$ e NDCG de $0{,}984 \pm 0{,}038$.

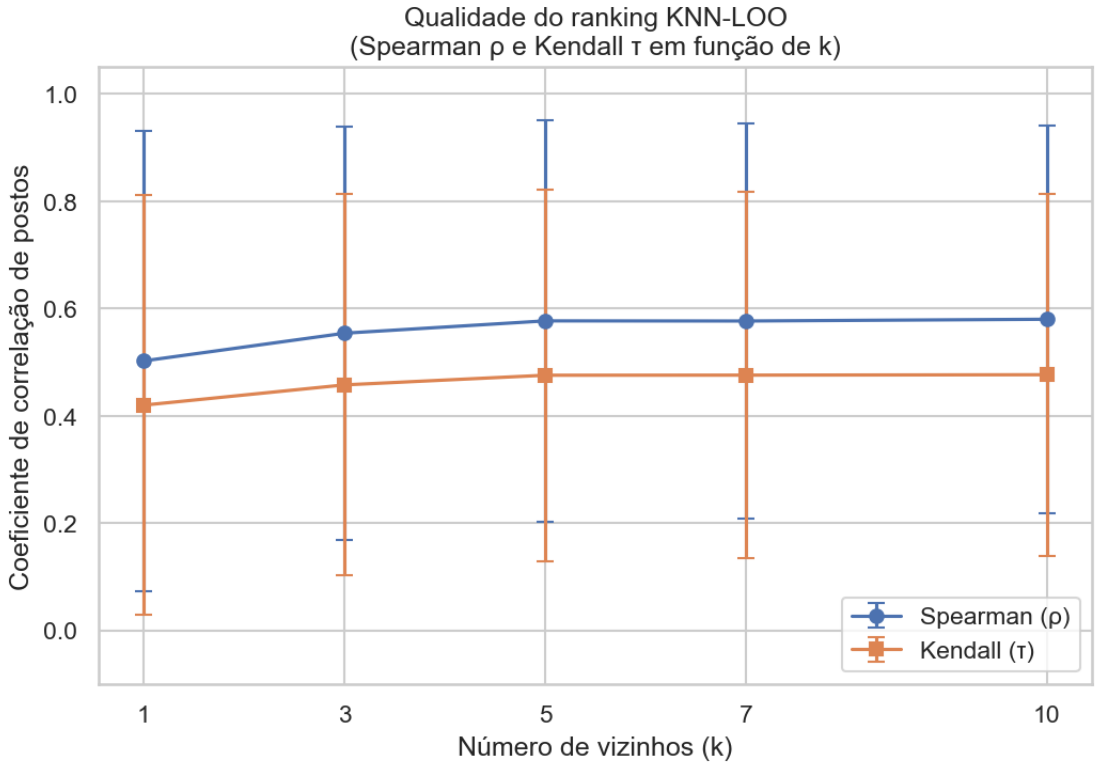


Fig. 2. Qualidade do ranking (correlações de Spearman ρ e Kendall τ, média e desvio-padrão) em função do número de vizinhos k na avaliação LOO.

Table I. Métricas de qualidade de ranking na avaliação LOO para $k = 10$ (média $\pm$ desvio-padrão, $n = 198$ folds válidos).

Métrica	**Valor**
Correlação de Spearman	$0{,}5801 \pm 0{,}3615$
Kendall Tau (τ)	$0{,}4767 \pm 0{,}3379$
Kendall Tau ponderado (τ_w)	$0{,}5222 \pm 0{,}3471$
NDCG	$0{,}9844 \pm 0{,}0384$

A diferença entre τ_w e τ – a variante ponderada supera a padrão em cerca de 4,5 pontos percentuais, em média – indica que o preditor é comparativamente *mais* preciso próximo ao topo do ranking do que ao longo de todo o ranking, exatamente a região de maior relevância prática para um usuário que inspeciona apenas os primeiros pipelines recomendados. Os valores elevados de NDCG (próximos de 0,98) podem, à primeira vista, parecer contraditórios com os escores moderados de Spearman/Kendall; a explicação é que o NDCG, por construção, é dominado pela relevância dos itens posicionados no topo e é calculado em escala com desconto logarítmico, permanecendo alto mesmo quando a ordem relativa dos pipelines intermediários e inferiores não é perfeitamente recuperada – reforçando, sob outro ângulo, que o preditor é mais confiável exatamente onde isso mais importa.

A análise de correlação estatística identifica cinco dimensões do embedding cujos valores se correlacionam significativamente com o escore de Kendall ponderado por dataset (todas com $p < 0{,}0001$), associadas a descritores de balanceamento de classes, dispersão de valores de atributos e conteúdo informacional – evidência de que o espaço de embeddings codifica estrutura genuinamente relevante para a recomendação de pipelines, e não atua como uma assinatura numérica opaca.

Table II. Correlações médias de Spearman / Kendall / Kendall ponderado: abordagem proposta vs. baselines e faixas de referência da literatura.

Abordagem	**Spearman**	**Kendall**	τ_w
Ranking aleatório	≈ 0	≈ 0	≈ 0
Ranking de média global	0,47	0,38	0,42
Proposto (k-NN, k=10)	0,58	0,48	0,52
Baseado em Dataset2Vec (lit.)		$\sim$ 0,55–0,70	
Schoenfeld et al. 2022 (lit.)		$\sim$ 0,40–0,70	

Demonstração em holdout. Em um dataset excluído de ambas as fases (tarefa OpenML 363713), o preditor com $k = 10$ obtém correlação de Spearman de 0,96, Kendall padrão de 0,87, Kendall ponderado de 0,81 e NDCG de 0,9995, ilustrando que, para datasets cujos embeddings caem próximos a regiões bem representadas do meta-conjunto, a abordagem consegue recuperar rankings quase indistinguíveis do real.

Comparação com baselines e a literatura. A Tabela II contrasta o preditor proposto com duas baselines simples: um ranking aleatório (correlações esperadas próximas de zero) e um ranking de "média global", que sempre recomenda pipelines ordenados por seu desempenho médio em todos os datasets de treino, ignorando o embedding de consulta. O preditor k-NN supera claramente ambas, mostrando que o embedding de fato carrega sinal específico do dataset que um ranking agnóstico à consulta não consegue explorar. A correlação de Spearman obtida ($0{,}58 \pm 0{,}36$) é também compatível com as faixas relatadas por abordagens comparáveis que utilizam representações neurais mais ricas – por exemplo, $\sim$0,55–0,70 para pipelines baseados em Dataset2Vec e $\sim$0,40–0,70 para as representações estruturadas de Schoenfeld et al. [2022] – sugerindo que um embedding estatístico comparativamente simples e totalmente reprodutível já constitui um ponto de partida competitivo.

Limitações. O embedding atual é puramente estatístico (não-neural), o preditor é um modelo simples baseado em instâncias (nenhum MLP ou outro metamodelo aprendido foi ainda avaliado sobre o mesmo meta-conjunto), a variância entre datasets permanece alta, e o arsenal de pipelines e os hiperparâmetros foram mantidos fixos para tornar o estudo tratável. Essas limitações apontam diretamente para as direções de trabalhos futuros descritas a seguir.

5. CONCLUSÃO

Este trabalho propôs e avaliou uma abordagem de meta-aprendizado para ranquear e recomendar pipelines de classificação a partir de embeddings estatísticos de datasets. Um meta-conjunto combinando 201 datasets, 60 pipelines e um embedding distribucional de 64 dimensões por dataset foi construído e caracterizado (Fase 1), e um preditor de ranking k-NN multi-saída foi treinado e avaliado por *Leave-One-Out* no nível de datasets (Fase 2). Os dois objetivos específicos definidos para o estudo foram atendidos: (i) o meta-conjunto construído mostra que rótulos de desempenho e meta-características de datasets carregam sinal suficiente para diferenciar boas e más configurações de pipeline, e (ii) o preditor resultante estima de forma confiável os rankings de pipelines para datasets inéditos, com correlações de Spearman, Kendall e Kendall ponderado de 0,58, 0,48 e 0,52 para $k = 10$, superando as baselines aleatória e agnóstica à consulta e equiparando-se às faixas relatadas por abordagens baseadas em embeddings neurais mais ricos. Uma análise estatística mostra ainda que diversas dimensões do embedding se correlacionam significativamente com a qualidade do ranqueamento, reforçando a interpretabilidade da representação proposta.

Como trabalhos futuros, pretende-se (i) substituir ou complementar o embedding estatístico por uma representação neural aprendida, como o Dataset2Vec [Jomaa et al. 2021]; (ii) avaliar metamodelos mais ricos (por exemplo, perceptrons multicamadas) sobre o mesmo meta-conjunto; (iii) expandir o arsenal de pipelines e permitir variação de hiperparâmetros; (iv) estudar a transferibilidade da abordagem

entre domínios; e (v) investigar mais a fundo a interpretabilidade do espaço de embeddings, incluindo as dimensões identificadas como significativamente correlacionadas com a qualidade do ranqueamento. O próprio meta-conjunto – 201 datasets × 60 pipelines avaliados por validação cruzada estratificada – é disponibilizado como um benchmark reutilizável para as comunidades de meta-aprendizado e AutoML.

ACKNOWLEDGMENT

Os autores agradecem ao Departamento Acadêmico de Computação da Universidade Tecnológica Federal do Paraná (UTFPR) pelo apoio institucional ao desenvolvimento deste trabalho. Registra-se ainda que este artigo deriva do Trabalho de Conclusão de Curso de J. V. Dos Santos Gomes, no qual J. Aikes Junior atuou como orientador e D. Pereira dos Santos como coorientador, sendo responsáveis pela definição da metodologia, pelo acompanhamento da condução dos experimentos e pela revisão crítica dos resultados que fundamentam este trabalho.

REFERENCES

Domingos, P. *O algoritmo mestre: como a busca pelo algoritmo de machine learning definitivo recriará nosso mundo*. Novatec Editora, 2017.

Jomaa, H. S., Schmidt-Thieme, L., and Grabocka, J. Dataset2vec: Learning dataset meta-features. *Data Mining and Knowledge Discovery* 35 (3): 964–985, 2021.

Schoenfeld, B., Seppi, K., and Giraud-Carrier, C. Metalearning using structure-rich pipeline representations for improved automl. *International Journal of Data Analysis Techniques and Strategies* 14 (1): 49–72, 2022.

Schoenfeld, B. J. *Metalearning by Exploiting Granular Machine Learning Pipeline Metadata*. M.S. thesis, Brigham Young University, 2020.

Vanschoren, J. Meta-learning: A survey. *arXiv preprint arXiv:1810.03548*, 2018.

Vanschoren, J., van Rijn, J. N., Bischl, B., and Torgo, L. Openml: Networked science in machine learning. *ACM SIGKDD Explorations Newsletter* 15 (2): 49–60, 2014.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., Carey, C. J., Polat, İ., Feng, Y., Moore, E. W., VanderPlas, J., Laxalde, D., Perktold, J., Cimrman, R., Henriksen, I., Quintero, E. A., Harris, C. R., Archibald, A. M., Ribeiro, A. H., Pedregosa, F., and van Mulbregt, P. Scipy 1.0: Fundamental algorithms for scientific computing in python. *Nature Methods* vol. 17, pp. 261–272, 2020.

Wolpert, D. H. and Macready, W. G. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation* 1 (1): 67–82, 1997.