Ranking Classification Pipelines with Statistical Dataset Embeddings: A Meta-Learning Approach

J. V. Dos Santos Gomes, J. Aikes Junior, D. Pereira dos Santos

Universidade Tecnológica Federal do Paraná (UTFPR), Brazil
joaogomes.2003@alunos.utfpr.edu.br, jorgejunior@utfpr.edu.br, davip@professores.utfpr.edu.br

Abstract. Classification pipeline selection depends on dataset characteristics and preprocessing choices. This work investigates pipeline ranking through meta-learning with deterministic statistical descriptors of labeled datasets. An archive of 201 OpenML tasks and 60 pipelines yields 193 eligible tasks in 165 groups after auditing. Phase 1 was fully reconstructed in 57900 model fits, with imputation, encoding, scaling and feature selection fitted exclusively on each training fold. All classifiers, including SVM, use identical training and test rows. Each dataset vector comprises 55 descriptors, nine padded zeros and L2 normalization. Five outer group partitions and inner neighborhood selection compare k-NN, Random Forest, global-mean and random-ranking baselines. Group-averaged weighted Kendall is 0.4280 for k-NN, 0.4768 for Random Forest and 0.4011 for the global mean. The Random Forest minus k-NN difference is 0.0515, with a descriptive 95% interval [0.0255, 0.0771]. Controlled comparisons retain tasks and partitions while replacing historical scores and recomputing descriptors. Error analysis identifies 13 tasks with nonpositive weighted correlation and 16 undefined cases. Artifacts include predictions, statuses, parameters, row indices and checksums. The evaluation remains retrospective and its intervals descriptive; expanding the pipeline arsenal and external validation remain future work.

CCS Concepts: • **Computing methodologies** → **Machine learning algorithms**; • **Information systems** → *Learning to rank*.

Keywords: AutoML, dataset embeddings, k-nearest neighbors, meta-learning, pipeline ranking

1. INTRODUÇÃO

A recomendação de pipelines depende da representação dos dados, dos algoritmos candidatos e do protocolo usado para medir desempenho. Em AutoML, distinguir espaço de busca, estratégia e avaliação permite controlar a origem de ganhos e limitações [Baratchi et al. 2024]. Este trabalho investiga o ranqueamento de 60 pipelines por meta-aprendizado a partir de descritores estatísticos de conjuntos rotulados.

Uma auditoria do acervo de 201 tarefas OpenML identificou tarefas relacionadas e oito casos sem suporte suficiente de classe para cinco folds. A revisão delimitou 193 tarefas em 165 grupos. Nesta etapa, os escores dos classificadores foram integralmente reconstruídos: imputação, codificação, escalonamento e seleção são ajustados apenas no treino, e SVM recebe as mesmas linhas dos demais algoritmos. Isso conclui a reconstrução antes pendente, preservando os resultados históricos como referência.

As contribuições são: (i) disponibilizar os escores reconstruídos com índices e estados de cada fold; (ii) comparar protocolos nas mesmas tarefas e grupos, distinguindo escores e representações; e (iii) reavaliar k-NN, Random Forest e baselines com ajuste interno e métricas complementares. O estudo continua retrospectivo e não trata reconstrução metodológica como garantia de aumento de métricas.

Versão de trabalho para revisão dos autores.

Manuscrito revisado, outubro de 2026.

2. TRABALHOS RELACIONADOS

Três eixos orientam a discussão: representação, recomendação e avaliação. No primeiro, Dataset2Vec aprende representações de conjuntos [Jomaa et al. 2021], enquanto o vetor deste estudo concatena estatísticas fixas sem treino neural. TabPFN [Hollmann et al. 2025] exemplifica reutilização de conhecimento entre problemas tabulares, mas sua tarefa preditiva difere do ranqueamento do arsenal aqui avaliado.

No eixo de recomendação, o enquadramento de Baratchi et al. [2024] separa espaço de busca, estratégia e avaliação. Manter os 60 candidatos controla a comparação entre metamodelos e protocolos, limitando a extrapolação a configurações não observadas. No eixo de avaliação, AMLB [Gijsbers et al. 2024] orienta comparações que consideram desempenho, recursos e falhas. Aqui, isso motiva preservar avisos, escores ausentes e condições equivalentes.

Os pressupostos de No Free Lunch não garantem ganho de um recomendador em dados reais; a relação entre os teoremas e vieses indutivos exige cuidado [Goldblum et al. 2024]. A evidência do presente estudo é obtida no próprio protocolo, sem converter números de tarefas diferentes em comparação direta de superioridade.

3. MATERIAIS E MÉTODOS

O procedimento compreende auditoria, reconstrução dos classificadores, representação de tarefas e avaliação por grupos. Escores históricos e reconstruídos permanecem em diretórios distintos.

3.1 Dados e Arsenal

São usadas tarefas de classificação supervisionada do OpenML [Vanschoren et al. 2014], com alvo oficial, 500–10.000 exemplos, ao menos duas classes e cinco exemplos por classe. Após remover colunas de data/hora, exigem-se atributos tabulares disponíveis. A regra não usa desempenho de recomendação. O catálogo inclui links, grupos, dimensionalidade, balanceamento e hashes. Preservam-se 193 tarefas, 179 nomes e 165 grupos; os grupos anteriores foram conferidos com IDs e fingerprints brutos, sem mudança nesta coleta.

O arsenal cruza StandardScaler, MinMaxScaler, RobustScaler e ausência; PCA, SelectKBest por ANOVA e ausência; e cinco classificadores. Os parâmetros explícitos são: Random Forest com 100 árvores; SVM RBF, C=1 e gamma scale; k-NN com cinco vizinhos; MLP (64,32), Adam e até 200 iterações; árvore com profundidade máxima 10. Seletores usam até dez componentes/atributos, limitados à dimensão disponível; PCA usa solver automático e semente 42. A semente controla a aleatoriedade dos demais componentes estocásticos. Demais parâmetros seguem a versão registrada da biblioteca.

3.2 Reconstrução Integral da Fase 1

Cada tarefa recebe cinco folds estratificados, com shuffle e semente 42. Os mesmos índices são usados em todos os pipelines, e cada linha é testada uma vez. Não há subamostra exclusiva da SVM. A mediana numérica é estimada no treino, preservando colunas vazias. Categorias recebem um marcador determinístico para ausência e codificador ordinal ajustado no treino; categorias desconhecidas recebem -1. Escalonadores e seletores usam apenas treino, e o teste recebe somente transformações já ajustadas.

Transformações comuns são reaproveitadas entre classificadores dentro do mesmo fold, sem compartilhar ajuste entre folds. A execução utiliza quatro processos inicialmente e seis após retomada dos checkpoints em tarefas diferentes, uma thread BLAS e um job por classificador. O ambiente é Python 3.14.2 e scikit-learn 1.8.0, com demais versões e ajustes operacionais nos manifestos.

São calculados acurácia balanceada e F1 macro em cada teste. O alvo do metamodelo é a média dos cinco folds de acurácia balanceada; falha em qualquer fold torna esse alvo ausente. Avisos de convergência são preservados como limitação do orçamento finito, sem serem descritos como convergência garantida. Foram executados 57900 ajustes, com 0 falhas, 0 escores agregados ausentes e 7703 avisos de convergência.

3.3 Vetor Estatístico

Para cada atributo numérico codificado, calculam-se média, desvio padrão populacional acrescido de 10^{-8}, mínimo, máximo, mediana, assimetria, curtose de Fisher e correlações de Pearson e Spearman com o alvo. Cada descritor é agregado por mínimo, percentil 25, média, percentil 75 e máximo entre atributos: 45 entradas.

Dez propriedades globais são concatenadas: $\log(1+N)$, $\log(1+P)$, número de classes, proporções majoritária e minoritária, entropia das proporções acrescidas de 10^{-8}, proporção de atributos constantes, média da correlação absoluta entre atributos com diagonal zerada e denominador P^2, média da proporção de valores únicos e $P/(N+10^{-8})$. Acrescentam-se nove zeros, aplica-se `nan_to_num` e norma L2; vetor nulo permanece nulo.

A meta-descrição usa a tarefa rotulada completa, separadamente da validação dos classificadores, sem usar predições ou escores dos folds. O cenário requer rótulos na consulta e não cobre dados sem rótulos. Correlações com códigos nominais multiclasses dependem de ordenação arbitrária. Não há treinamento da representação.

3.4 Metamodelos, Partições e Métricas

O k-NN estima as 60 saídas por média dos vizinhos ponderada por $1/(d+10^{-8})$, com distância euclidiana. O Random Forest meta é um regressor multi-saída nativo com 200 árvores, mínimo de duas observações por folha, max features 1,0 e semente 42. As baselines são média global por pipeline somente no treino e escores uniformes aleatórios com semente 42 acrescida do fold. Avalia-se também k-NN com padronização ajustada no treino.

GroupKFold externo usa cinco divisões, shuffle e semente 42. Quatro divisões internas por grupos selecionam $k \in \{1,3,5,7,10\}$ pela média de Kendall ponderado por grupo, com menor k em empate. Teste externo não participa da seleção, padronização ou imputação de alvos. Medianas de alvos são estimadas no treino; colunas sem observação no treino ficam fora da avaliação correspondente. Escores reais ausentes no teste nunca são imputados para avaliar ranking.

Spearman e Kendall tau-b avaliam ordenação global. Kendall ponderado padrão usa pesos hiperbólicos aditivos e média de duas ordenações lexicográficas real/predito, sem p-valor definido. NDCG usa ganho linear da acurácia e desconto logarítmico; reportam-se NDCG completo e NDCG@5. Regret@1 é a perda em relação à melhor acurácia disponível ao recomendar o primeiro pipeline, e Regret@5 usa o melhor entre os cinco primeiros. NDCG trata empates pela média; regret usa ordem estável de colunas.

As médias são calculadas dentro de grupo e depois entre grupos. Intervalos descritivos de 95% usam 2.000 reamostragens de grupos com semente 42. A sobreposição de treinos limita inferência. O diagnóstico usa cinco associações exploratórias por grupo com ajuste Benjamini–Hochberg, sem interpretação causal.

3.5 Condições de Comparação

As mesmas tarefas, grupos e folds avaliam: (i) matrizes históricas; (ii) escores reconstruídos e vetores históricos; e (iii) escores e vetores reconstruídos, a condição principal. As entradas usam precisão

float32 em todas as condições, compatível com as matrizes históricas; os escores reconstruídos de origem ficam preservados em float64. A diferença pareada usa casos avaliáveis em ambas as condições. Comparar escores históricos e novos também altera os próprios rankings reais usados como alvo; por isso, a diferença não isola ganho de capacidade preditiva sob uma única verdade de referência. A comparação com vetor fixo ajuda a separar representação e escores, mantendo essa limitação.

4. RESULTADOS E DISCUSSÃO

Esta seção compara a referência revisada com a reconstrução e apresenta metamodelos e falhas. Os números antigos de LOO por tarefa não são usados como referência direta, pois o protocolo era distinto.

4.1 Comparação Controlada

A Tabela I apresenta Kendall ponderado nas mesmas tarefas e partições por grupos. O k-NN passa de 0,3995 com escores históricos para 0,4280 na reconstrução completa; Random Forest passa de 0,4309 para 0,4768. Os intervalos pareados e a condição de vetores históricos com novos escores estão nos CSVs. Médias e diferenças pareadas podem usar suportes distintos quando uma correlação é indefinida.

A mudança pareada foi $-0{,}0093$ para k-NN, com intervalo descritivo $[-0{,}0282; 0{,}0092]$, e 0,0059 para Random Forest, com intervalo $[-0{,}0085; 0{,}0202]$. O intervalo da mudança do k-NN ajustado abrange zero. O intervalo da mudança do Random Forest abrange zero. A elevação das médias gerais não estabelece melhoria uniforme, pois também muda o suporte de correlações definidas.

Table I. Referência revisada e reconstrução da Fase 1.

Método	τ_w histórico	τ_w reconstruído	Diferença pareada
Aleatório	0,0024	0,0012	−0,0003
Média global	0,3690	0,4011	0,0024
k-NN ajustado	0,3995	0,4280	−0,0093
k-NN padronizado	0,4138	0,4539	0,0090
Random Forest	0,4309	0,4768	0,0059

4.2 Avaliação Principal

A Tabela II apresenta os metamodelos sobre a matriz reconstruída. O k-NN possui correlações definidas em 177 tarefas de 149 grupos; os k escolhidos nos treinos externos foram 5, 10, 10, 10, 10. A diferença Random Forest menos k-NN é 0,0515, com intervalo descritivo $[0{,}0255; 0{,}0771]$. O intervalo descritivo sugere vantagem do Random Forest sobre o k-NN neste acervo. A Figura 1 mostra os intervalos por grupo.

O regret@1 é 0,0336 para k-NN, 0,0207 para Random Forest e 0,0260 para média global. A baseline aleatória já apresenta NDCG@5 0,8843, ilustrando por que NDCG alto não demonstra top-5 correto. Correlações, relevância e perda da primeira recomendação são interpretadas conjuntamente.

O diagnóstico registra 13 tarefas com Kendall ponderado não positivo e 16 indefinidas. Há 14 tarefas com escores reais constantes e 2 com predição constante e escores reais variáveis; casos indefinidos não são convertidos em acerto ou zero. Entre as menores correlações definidas estão: tarefa 9976 ($\tau_w = -0{,}4184$, $N = 2600$, $P = 500$, proporção majoritária 0,5000); tarefa 3512 ($\tau_w = -0{,}3760$, $N = 600$, $P = 60$, proporção majoritária 0,1667); tarefa 363159 ($\tau_w = -0{,}3330$, $N = 4531$, $P =$

Table II. Metamodelos após reconstrução: médias por grupo.

Método	Spearman	τ_w	NDCG@5	Regret@1	Tarefas/grupos (τ_w)
Aleatório	−0,0114	0,0012	0,8843	0,0785	179/151
Média global	0,4277	0,4011	0,9522	0,0260	179/151
k-NN ajustado	0,4897	0,4280	0,9502	0,0336	177/149
k-NN padronizado	0,5148	0,4539	0,9533	0,0259	179/151
Random Forest	0,5293	0,4768	0,9632	0,0207	179/151

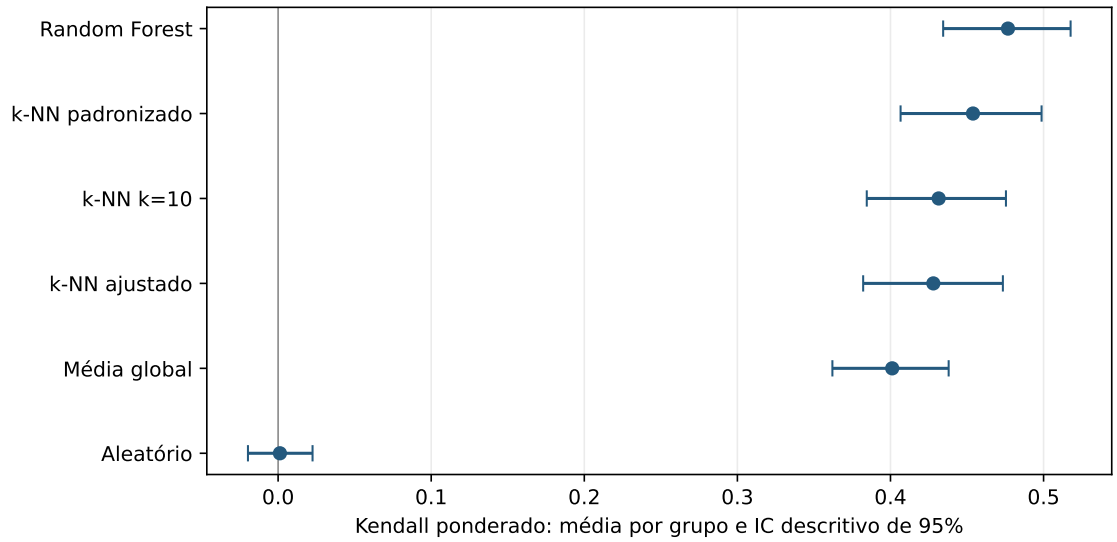


Fig. 1. Kendall ponderado e intervalos descritivos após reconstrução.

1, proporção majoritária 0,0603). Nenhuma das cinco associações exploratórias permaneceu abaixo de $q = 0{,}05$ após ajuste Benjamini–Hochberg. Essas associações não demonstram causalidade ou explicação exclusiva da instabilidade.

4.3 Limitações

A reconstrução conclui o tratamento antes pendente na Fase 1, sem tornar a avaliação externa ou prospectiva. Permanecem grupos potencialmente incompletos, codificação nominal ordinal, rótulos necessários na consulta, hiperparâmetros fixos e orçamento de MLP sujeito a avisos de convergência. A auditoria identifica 30 tarefas somente categóricas e 18 com nomes sugestivos de identificadores/caminhos, sem usá-los para seleção após observar resultados. Os intervalos são descritivos devido à sobreposição dos treinos. Comparar dois preditores sobre um vetor não constitui ablação completa de representações. O piloto anterior de 180 avaliações permanece separado e não equivale a expandir todo o arsenal.

5. CONCLUSÃO

O estudo reconstruiu a avaliação dos 60 pipelines em dados brutos, com tratamento ajustado no treino e amostras equivalentes para todos os classificadores. Os escores, índices, parâmetros, estados e hashes permitem inspeção da execução. A reavaliação de metamodelos e a comparação controlada delimitam os efeitos observados sem confundir melhoria do protocolo com aumento obrigatório de métricas.

As próximas etapas são ampliar o arsenal, estudar orçamento e convergência, comparar representações e validar em conjuntos externos coletados após o desenvolvimento. A reconstrução completa da Fase 1 deixa de ser uma pendência, preservando os limites retrospectivos do benchmark.

ACKNOWLEDGMENT

Os autores agradecem à Universidade Tecnológica Federal do Paraná pelo apoio institucional e à orientação do TCC que deu origem a este estudo.

REFERENCES

Baratchi, M., Wang, C., Limmer, S., van Rijn, J. N., Hoos, H., Bäck, T., and Olhofer, M. Automated machine learning: past, present and future. *Artificial Intelligence Review* vol. 57, pp. 122, 2024.

Gijsbers, P., Bueno, M. L. P., Coors, S., LeDell, E., Poirier, S., Thomas, J., Bischl, B., and Vanschoren, J. AMLB: an AutoML benchmark. *Journal of Machine Learning Research* 25 (101): 1–65, 2024.

Goldblum, M., Finzi, M. A., Rowan, K., and Wilson, A. G. Position: The no free lunch theorem, kolmogorov complexity, and the role of inductive biases in machine learning. In *Proceedings of the 41st International Conference on Machine Learning*. Proceedings of Machine Learning Research, vol. 235. PMLR, pp. 15788–15808, 2024.

Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T., and Hutter, F. Accurate predictions on small data with a tabular foundation model. *Nature* vol. 637, pp. 319–326, 2025.

Jomaa, H. S., Schmidt-Thieme, L., and Grabocka, J. Dataset2vec: Learning dataset meta-features. *Data Mining and Knowledge Discovery* 35 (3): 964–985, 2021.

Vanschoren, J., van Rijn, J. N., Bischl, B., and Torgo, L. Openml: Networked science in machine learning. *ACM SIGKDD Explorations Newsletter* 15 (2): 49–60, 2014.

Manuscrito revisado, outubro de 2026.