UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

JOÃO VICTOR DOS SANTOS GOMES

META-APRENDIZADO PARA AVALIAÇÃO DA QUALIDADE DO PRÉ-PROCESSAMENTO E RECOMENDAÇÃO OTIMIZADA DE PIPELINES EM AUTOML

MEDIANEIRA

2026

JOÃO VICTOR DOS SANTOS GOMES

META-APRENDIZADO PARA AVALIAÇÃO DA QUALIDADE DO PRÉ-PROCESSAMENTO E RECOMENDAÇÃO OTIMIZADA DE PIPELINES EM AUTOML

Meta-learning for Preprocessing Quality Assessment and Optimized Pipeline Recommendation in AutoML

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Ciência da Computação do Curso de Bacharelado em Ciência da Computação da Universidade Tecnológica Federal do Paraná.

Orientador: Prof. Dr. Jorge Aikes Junior

Coorientador: Prof. Dr. Davi Pereira dos Santos

MEDIANEIRA

2026

4.0 Internacional

Esta licença permite remixe, adaptação e criação a partir do trabalho, para fins não comerciais, desde que sejam atribuídos créditos ao(s) autor(es) e que licenciem as novas criações sob termos idênticos. Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

JOÃO VICTOR DOS SANTOS GOMES

META-APRENDIZADO PARA AVALIAÇÃO DA QUALIDADE DO PRÉ-PROCESSAMENTO E RECOMENDAÇÃO OTIMIZADA DE PIPELINES EM AUTOML

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Ciência da Computação do Curso de Bacharelado em Ciência da Computação da Universidade Tecnológica Federal do Paraná.

Prof. Dr. Jorge Aikes Junior
Orientador
Universidade Tecnológica Federal do Paraná

Prof. Dr. Davi Pereira dos Santos
Coorientador
Universidade Tecnológica Federal do Paraná

Prof. Dr. Jandrei Sartori Spancerski
Membro da banca examinadora
Universidade Tecnológica Federal do Paraná

MEDIANEIRA

2026

AGRADECIMENTOS

Agradeço ao meu orientador, Prof. Dr. Jorge Aikes Junior, e ao meu coorientador, Prof. Dr. Davi Pereira dos Santos, pela dedicação, pela disponibilidade e pelos direcionamentos que tornaram possível a realização deste trabalho.

Agradeço aos meus pais, pelo apoio incondicional e pelo incentivo constante ao longo de toda a minha trajetória acadêmica.

Agradeço também aos amigos que estiveram comigo ao longo dos anos de faculdade, compartilhando as dificuldades e as conquistas dessa caminhada.

Por fim, agradeço à Universidade Tecnológica Federal do Paraná (UTFPR), Câmpus Medianeira, pela estrutura e pelo apoio institucional oferecidos durante o desenvolvimento deste trabalho.

RESUMO

A seleção de pipelines de classificação depende das características dos dados e das etapas de pré-processamento. Este trabalho investiga seu ranqueamento por meta-aprendizado com representação estatística determinística de conjuntos rotulados. O acervo histórico contém 201 tarefas OpenML e 60 pipelines; a auditoria delimita 193 tarefas elegíveis em 165 grupos. A Fase 1 foi integralmente reconstruída em 57900 ajustes, com imputação, codificação, escalonamento e seleção estimados somente no treino de cada fold. Todos os classificadores, inclusive SVM, recebem as mesmas amostras. A representação usa 55 descritores, nove zeros e normalização L2. Cinco divisões externas por grupos e ajuste interno de k comparam k-NN, Random Forest, média global e ranking aleatório. O Kendall ponderado médio por grupo foi $0{,}4280$ para k-NN, $0{,}4768$ para Random Forest e $0{,}4011$ para média global. A diferença Random Forest menos k-NN foi $0{,}0515$, com intervalo descritivo de 95% $[0{,}0255; 0{,}0771]$. A comparação controlada mantém tarefas e folds ao substituir escores históricos e recalcular a representação. O diagnóstico registra 13 tarefas com correlação ponderada não positiva e 16 indefinidas. Os artefatos incluem predições, estados, parâmetros, índices e hashes. A avaliação permanece retrospectiva e seus intervalos são descritivos; a expansão do arsenal e a validação externa são próximas etapas.

Palavras-chave: meta-aprendizado; automl; recomendação de pipelines; ranqueamento; embeddings de datasets.

ABSTRACT

Classification pipeline selection depends on dataset characteristics and preprocessing choices. This work investigates pipeline ranking through meta-learning with deterministic statistical descriptors of labeled datasets. An archive of 201 OpenML tasks and 60 pipelines yields 193 eligible tasks in 165 groups after auditing. Phase 1 was fully reconstructed in 57900 model fits, with imputation, encoding, scaling and feature selection fitted exclusively on each training fold. All classifiers, including SVM, use identical training and test rows. Each dataset vector comprises 55 descriptors, nine padded zeros and L2 normalization. Five outer group partitions and inner neighborhood selection compare k-NN, Random Forest, global-mean and random-ranking baselines. Group-averaged weighted Kendall is 0.4280 for k-NN, 0.4768 for Random Forest and 0.4011 for the global mean. The Random Forest minus k-NN difference is 0.0515, with a descriptive 95% interval [0.0255, 0.0771]. Controlled comparisons retain tasks and partitions while replacing historical scores and recomputing descriptors. Error analysis identifies 13 tasks with nonpositive weighted correlation and 16 undefined cases. Artifacts include predictions, statuses, parameters, row indices and checksums. The evaluation remains retrospective and its intervals descriptive; expanding the pipeline arsenal and external validation remain future work.

Keywords: meta-learning; automl; pipeline recommendation; ranking; dataset embeddings.

LISTA DE FIGURAS

Figura 1 – Kendall ponderado após reconstrução da Fase 1 . . . . . **34**

Figura 2 – Diagnóstico do k-NN com escores reconstruídos **34**

LISTA DE TABELAS

Tabela 2 – Comparativo entre trabalhos relacionados e a proposta deste TCC . . . 24

Tabela 3 – Comparação da referência revisada com a reconstrução integral 32

Tabela 4 – Metamodelos sobre escores reconstruídos: médias por grupo 33

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

Siglas

ANOVA	*Analysis of Variance*
AutoML	*Automated Machine Learning*
BADGE	*Batch Active learning by Diverse Gradient Embeddings*
CIFAR-10	*Canadian Institute for Advanced Research 10 classes*
CIFAR-100	*Canadian Institute for Advanced Research 100 classes*
D3M	*Data-Driven Discovery of Models*
DAG	*Directed Acyclic Graph*
DARPA	*Defense Advanced Research Projects Agency*
DBTC	*Decision Boundary Topological Complexity*
DT	*Decision Tree*
FashionMNIST	*Fashion Modified National Institute of Standards and Technology database*
ISIC2019	*International Skin Imaging Collaboration 2019 Dataset*
k-NN	*k-Nearest Neighbors*
LSTM	*Long Short-Term Memory*
MEGA	*Meta-learning Guided Algorithm Recommendation*
ML	*Machine Learning*
MLP	*Multilayer Perceptron*
MNIST	*Modified National Institute of Standards and Technology database*
NDCG	*Normalized Discounted Cumulative Gain*
PCA	*Principal Component Analysis*
RF	*Random Forest*
SVM	*Support Vector Machine*
TCM	*TypiClust-Margin*
UCI	*University of California, Irvine*

SUMÁRIO

1 Introdução 11

1.1 Objetivos 12

1.2 Justificativa 12

1.3 Estrutura do Trabalho 13

2 Referencial Teórico 14

2.1 Aprendizado de Máquina e AutoML 14

2.2 Meta-aprendizado 15

2.3 Meta-características e Caracterização de Conjuntos de Dados 16

2.4 Aprendizado Ativo 16

2.5 Seleção e estrutura de *pipelines* 17

2.6 Componentes do Arsenal Experimental 18

2.7 Embeddings de Conjuntos de Dados e Métricas de Ranking 19

2.7.1 Embeddings de Conjuntos de Dados 19

2.7.2 Métricas de Avaliação de Ranking 20

2.8 Trabalhos Relacionados 21

2.8.1 Representação de Conjuntos de Dados e Meta-características 21

2.8.2 Sistemas de Recomendação de Algoritmos e Pipelines 22

2.8.3 Avaliação de Fronteiras de Decisão e Aprendizado Ativo 23

2.8.4 Síntese Comparativa 24

2.9 Avaliação Contemporânea de AutoML e Meta-aprendizado 24

3 Materiais e Métodos 26

3.1 Materiais e Fonte dos Dados 26

3.1.1 Ambiente Computacional 26

3.2 Fase 1: Escores em Dados Brutos 27

3.2.1 Arsenal de 60 Pipelines 27

3.2.2 Métricas, Avisos e Resultados Ausentes 27

3.3 Representação Estatística das Tarefas 28

3.4 Fase 2: Predição e Avaliação por Grupos 28

3.4.1 Métricas de Ranqueamento 29

3.4.2 Comparação Controlada e Diagnóstico 29

3.5 Reprodutibilidade e Delimitação 30
4 Experimentos e Resultados 31
4.1 Reconstrução Integral da Fase 1 31
4.2 Comparação Controlada das Condições 32
4.3 Avaliação Principal dos Metamodelos 33
4.4 Diagnóstico de Falhas 33
4.5 Discussão e Limitações 34
5 Conclusão 36
5.1 Síntese dos Resultados 36
5.2 Atendimento dos Objetivos 36
5.3 Limitações e Perspectivas 37
REFERÊNCIAS 38

1 INTRODUÇÃO

A seleção do algoritmo mais adequado para um determinado problema de aprendizado de máquina (ML, *Machine Learning*) é, reconhecidamente, um dos maiores desafios enfrentados por profissionais da área. Isso ocorre porque não existe um algoritmo universalmente superior para todos os tipos de dados, conforme reforçado pelo Teorema *No Free Lunch* Wolpert e Macready (1997), que demonstra formalmente que, em média sobre todos os problemas possíveis, qualquer dois algoritmos de otimização ou aprendizado têm desempenho equivalente — implicando que a superioridade de um algoritmo em um domínio necessariamente vem acompanhada de inferioridade em outro. As características intrínsecas dos dados — como dimensionalidade, balanceamento de classes, distribuição e presença de ruídos — impactam diretamente o desempenho dos modelos, tornando inviável a adoção de uma abordagem única e generalista.

Nesse cenário, o desenvolvimento de pipelines eficientes em ML exige uma combinação cuidadosa de três componentes fundamentais: representação, avaliação e otimização, conforme proposto por Domingos (2017). A representação define o espaço de hipóteses possível; a avaliação, os critérios que distinguem bons modelos de ruins; e a otimização, os métodos de busca que encontram o modelo mais adequado. Tradicionalmente, a construção desses pipelines depende fortemente da expertise humana, que realiza sucessivas tentativas e ajustes manuais.

Com o objetivo de reduzir esse esforço, surgem as abordagens de *AutoML* (*Automated Machine Learning*), que automatizam desde a seleção de algoritmos até o ajuste de hiperparâmetros. Deste modo, como destacam Schoenfeld (2020) e Vanschoren (2018), a eficácia dos sistemas de AutoML se amplia quando são utilizados modelos de meta-aprendizado, capazes de aprender a partir da experiência acumulada em múltiplos problemas anteriores.

O meta-aprendizado, ou aprendizado para aprender, estrutura-se na coleta de metadados e na extração de *meta-características* dos conjuntos de dados — atributos que capturam aspectos estatísticos, estruturais e informacionais dos dados Schoenfeld, Seppi e Giraud-Carrier (2022). Com isso, torna-se possível treinar metamodelos capazes de prever, de maneira informada, quais algoritmos ou pipelines possuem maior chance de sucesso em um novo problema.

A avaliação de pipelines precisa considerar conjuntamente o classificador e o *pré-processamento dos dados*. Escalas divergentes, valores ausentes e escolhas de codificação ou seleção de atributos podem alterar o desempenho de uma configuração. Além de comparar essas combinações, é necessário estimar suas transformações somente nos dados de treino, preservando o teste para avaliar a capacidade de generalização.

Diante desse cenário, este trabalho investiga o ranqueamento e a recomendação de pipelines de classificação por meta-aprendizado. A proposta compreende: (i) auditar um acervo histórico de 201 tarefas OpenML e reconstruir os escores de 60 pipelines sobre 193 tarefas elegíveis, com pré-processamento ajustado somente no treino e amostras equivalentes para todos os classificadores; (ii) representar cada tarefa rotulada por um vetor estatístico determinístico

de 55 descritores e nove zeros; e (iii) comparar k-NN e Random Forest multi-saída com baselines, usando validação por grupos, ajuste interno e comparação controlada com os escores históricos. A avaliação inclui 165 grupos e permanece retrospectiva, sem inferir superioridade universal a partir das métricas do benchmark.

A avaliação de recomendações exige distinguir representação, preditor e benchmark. A revisão de Baratchi *et al.* (2024) organiza AutoML em espaço de busca, estratégia e avaliação; essa distinção motiva controlar o arsenal ao comparar metamodelos.

1.1 Objetivos

Este trabalho tem como objetivo geral desenvolver e avaliar um sistema de meta-aprendizado baseado em embeddings estatísticos de conjuntos de dados para ranqueamento e recomendação de pipelines de classificação, capaz de identificar, a partir das características do conjunto de dados de entrada, quais configurações de pré-processamento e classificação apresentam maior probabilidade de sucesso preditivo. Para alcançar esse objetivo geral, foram definidos os seguintes objetivos específicos:

- Avaliar, por meio da construção de um meta-conjunto — repositório de conhecimento contendo descrições de pipelines, embeddings dos conjuntos de dados e rótulos de desempenho obtidos por validação cruzada estratificada —, se metadados de desempenho e meta-características de conjuntos de dados carregam sinal suficiente para diferenciar boas e más combinações de pré-processamento e classificação;
- Construir e avaliar um modelo preditivo capaz de estimar, a partir de metacaracterísticas dos dados, o ranking de adequação de diferentes configurações de pré-processamento e classificação.

1.2 Justificativa

A relevância deste trabalho está na articulação entre duas decisões experimentais. A primeira é avaliar conjuntamente escalonamento, seleção de atributos e classificação, preservando a identidade de cada pipeline. Essa abordagem permite investigar como diferentes combinações se comportam no mesmo conjunto de dados e evita atribuir ao classificador, isoladamente, os resultados de todo o fluxo de processamento.

A segunda decisão refere-se à forma de avaliação: recomendar apenas um pipeline não descreve a qualidade da ordenação dos demais candidatos. O ranqueamento permite examinar tanto a associação entre as ordens real e predita quanto a utilidade das primeiras recomendações. Por isso, este estudo combina correlações de postos, NDCG e regret, sem pressupor que uma única métrica represente todos esses aspectos.

O trabalho investiga essas decisões ao: (i) avaliar pipelines como combinações de pré-processamento e classificação; (ii) adotar ranqueamento como tarefa de recomendação; e (iii) utilizar métricas complementares para avaliar ordenação e utilidade das recomendações. O acervo histórico de 201 tarefas e 60 pipelines foi auditado, e a avaliação principal usa 193 tarefas em 165 grupos com escores integralmente reconstruídos. A disponibilização de configurações, índices e resultados por fold integra a contribuição. Não se infere superioridade por escala ou métricas de protocolos distintos.

1.3 Estrutura do Trabalho

Este trabalho está organizado em cinco capítulos:

- **Capítulo 1 – Introdução:** apresenta o contexto, o problema de pesquisa, os objetivos, a justificativa e a estrutura geral do trabalho;
- **Capítulo 2 – Referencial Teórico:** discute os fundamentos de aprendizado de máquina, AutoML, meta-aprendizado, meta-características para caracterização de conjuntos de dados, aprendizado ativo, estrutura de pipelines, componentes de pré-processamento e classificação, embeddings de conjuntos de dados e métricas de ranqueamento, e revisa os principais trabalhos relacionados nas áreas de representação de conjuntos de dados por embeddings, sistemas de recomendação de algoritmos e pipelines via meta-aprendizado, e análise de complexidade de fronteiras de decisão;
- **Capítulo 3 – Materiais e Métodos:** descreve os materiais utilizados, a metodologia experimental em duas fases — construção do meta-conjunto e meta-aprendizado por ranqueamento —, os preditores k-NN e Random Forest, a auditoria, a validação por grupos e as métricas de ranking;
- **Capítulo 4 – Experimentos e Resultados:** apresenta a reconstrução integral da Fase 1, a comparação controlada com os escores históricos, a avaliação de metamodelos por grupos e o diagnóstico de erros;
- **Capítulo 5 – Conclusão:** sintetiza as contribuições do trabalho, verifica o atendimento dos objetivos, discute limitações identificadas e propõe direções para pesquisas futuras.

2 REFERENCIAL TEÓRICO

O aprendizado de máquina moderno envolve uma série de decisões interdependentes que impactam diretamente a eficácia dos modelos, desde o pré-processamento dos dados até a escolha e configuração dos algoritmos. A crescente complexidade desses processos impulsionou o surgimento do *AutoML*, cujo objetivo é automatizar etapas críticas de um pipeline preditivo. No entanto, para que essa automação seja eficiente, é necessário compreender os fundamentos que orientam tais decisões.

Este capítulo apresenta os principais conceitos que embasam a proposta deste trabalho, abordando inicialmente os fundamentos do Aprendizado de Máquina e a estrutura dos sistemas de *AutoML*. Em seguida, discute-se o meta-aprendizado como estratégia para reutilizar conhecimento adquirido em problemas anteriores, otimizando escolhas futuras. Também são exploradas as meta-características, essenciais para caracterizar conjuntos de dados e treinar metamodelos eficazes, bem como o aprendizado ativo, que visa otimizar o processo de rotulagem. Por fim, são apresentadas estratégias para seleção e estruturação de pipelines, os componentes de pré-processamento e classificação utilizados no experimento, as representações vetoriais de conjuntos de dados e as métricas de ranqueamento adotadas na avaliação.

2.1 Aprendizado de Máquina e AutoML

A aprendizagem de máquina envolve sistemas que aprendem automaticamente a partir de dados, sem necessidade de programação explícita do modelo. Domingos (2017) destaca que, para não se perder na variedade de algoritmos disponíveis, deve-se encarar o aprendizado como a combinação de três componentes principais: representação, avaliação e otimização. Nesse contexto:

- **Representação:** define a linguagem formal dos classificadores que o sistema pode aprender, isto é, o espaço de hipóteses permitido. Se um classificador não está nesse espaço, ele não pode ser obtido pelo aprendizado;
- **Avaliação:** função objetivo utilizada para distinguir classificadores bons de maus (por exemplo, acurácia, erro quadrático). Em geral, há uma função interna de otimização distinta da métrica externa desejada;
- **Otimização:** método de busca no espaço de hipóteses para encontrar o classificador de maior pontuação. Técnicas comuns incluem busca combinatória, algoritmos evolucionários, gradiente etc.

A automação desses componentes é o foco do AutoML. Sistemas de AutoML têm se mostrado eficazes ao empregar *metamodelos* — modelos treinados sobre o histórico de desempenho de algoritmos em execuções anteriores, e não diretamente sobre os dados do problema-

alvo — de forma *offline* (isto é, previamente, a partir de execuções já realizadas em outras bases) para guiar a seleção de algoritmos e parâmetros, abordagem detalhada na Seção 2.2. Em particular, Schoenfeld (2020) observa que sistemas AutoML obtêm melhor desempenho usando metamodelos offline para estimar o desempenho de modelos. Vanschoren (2018) aponta também que o meta-aprendizado pode acelerar e aprimorar o projeto de pipelines de ML, substituindo abordagens manuais por soluções aprendidas de forma orientada por dados.

2.2 Meta-aprendizado

O meta-aprendizado, ou "aprender a aprender"Vilalta e Drissi (2002), é a ciência de observar sistematicamente como diferentes abordagens de aprendizado de máquina performam em múltiplas tarefas, e então aprender com essa experiência (metadados) para resolver novas tarefas mais rapidamente, de modo a construir sistemas de aprendizado autoadaptativos que melhoram seu viés indutivo dinamicamente com a experiência acumulada Brazdil *et al.* (2008). Em outras palavras, utiliza-se o histórico de desempenho de algoritmos em uma coleção de bases de dados para treinar um *metamodelo* (modelo treinado sobre metadados de execuções anteriores, e não diretamente sobre os dados do problema-alvo) que pode prever o melhor algoritmo ou configuração para um novo problema. Adicionalmente, Schoenfeld, Seppi e Giraud-Carrier (2022) mostraram que, em vez de tratar modelos como caixas-pretas, pode-se explorar metadados granulares dos pipelines para melhorar a previsão de desempenho.

As abordagens de meta-aprendizado podem ser *offline* ou *online*. Em métodos *offline*, diversos pipelines são executados previamente em coleções de conjunto de dados e os resultados formam o meta conjunto usado para treinar o metamodelo. Sistemas AutoML como o Auto-sklearn Feurer *et al.* (2015) e o SmartML Maher e Sakr (2019) ilustram esse caso, utilizando os resultados de múltiplas execuções em bases conhecidas para guiar a busca em novas bases. Em contrapartida, métodos *online*, como o TPOT (OLSON *et al.*, 2016), atualizam o aprendizado à medida que geram pipelines no próprio problema de interesse.

Além disso, benchmarks específicos como o *meta conjunto*, proposto por Triantafillou *et al.* (2020), foram desenvolvidos para avaliar modelos de few-shot learning e meta-aprendizado em cenários mais realistas e desafiadores. O *meta conjunto* é composto por um conjunto diversificado de conjuntos de dados que permite avaliar a capacidade dos meta-modelos de generalizar para novos domínios e tarefas com poucos exemplos. A proposta introduz variações no número de classes, tamanho de conjuntos de suporte e testes com desbalanceamento, promovendo uma avaliação mais robusta dos métodos de meta-aprendizado.

Em todos os casos, o objetivo é transferir conhecimento entre tarefas: utilizar metadados e meta características coletados em problemas anteriores para reduzir o tempo e esforço de modelagem em novos problemas.

2.3 Meta-características e Caracterização de Conjuntos de Dados

A caracterização de dados por meio de *meta características* é essencial para o meta-aprendizado. Meta características são atributos que descrevem propriedades estatísticas e estruturais de um conjunto de dados, e servem de entrada para os metamodelos. Por exemplo, Schoenfeld, Seppi e Giraud-Carrier (2022) extraíram 72 meta características de cada base de dados, incluindo categorias simples, estatísticas, informações teóricas, *landmarking* e baseadas em modelo. Esses grupos podem ser definidos genericamente da seguinte forma:

- **Simples:** propriedades elementares do conjunto, como número de instâncias, número de atributos, proporção de classes;
- **Estatísticas:** medidas como médias, variâncias e correlações dos atributos;
- **Informacionais:** métricas de teoria da informação, como entropia das classes e entropia dos atributos;
- **Landmarking:** desempenho de algoritmos simples e rápidos (por exemplo, taxa de erro de 1-vizinho mais próximo, árvore de decisão rasa) no conjunto de dados;
- **Baseadas em modelo:** características derivadas de modelos treinados, como profundidade média de árvores de decisão, coeficientes de regressão, etc.

Essas meta características capturam informações relevantes que permitem medir similaridades entre conjuntos de dados e orientar o aprendizado Feurer, Springenberg e Hutter (2015). Muitas pesquisas utilizam repositórios de dados públicos; por exemplo, o conjunto de 194 bases usado por Schoenfeld, Seppi e Giraud-Carrier (2022) provém do programa D3M (*Data-Driven Discovery of Models*), iniciativa da DARPA voltada à automação da ciência de dados Lippmann, Campbell e Campbell (2016), e inclui conjuntos de dados originados de repositórios como o OpenML Vanschoren *et al.* (2014) e o UCI Machine Learning Repository (DUA; GRAFF, 2019). Cada instância do meta conjunto consiste no vetor de metacaracterísticas do conjunto de dados e na estrutura do pipeline avaliado, associado ao respectivo desempenho (por exemplo, medida F1) obtido naquela base. Esse meta conjunto (meta características + descrição de pipeline + desempenho) é então utilizado para treinar metamodelos capazes de prever ou ranquear pipelines em novos conjuntos de dados.

2.4 Aprendizado Ativo

O aprendizado ativo é uma abordagem em que o algoritmo seleciona interativamente quais instâncias devem ser rotuladas para melhorar seu desempenho com poucos dados rotulados Cohn, Atlas e Ladner (1994). Settles (2009) descreve que a ideia central do aprendizado

ativo é permitir que o sistema escolha os exemplos a serem rotulados, de forma que se atinja maior precisão com um número reduzido de etiquetas. Em outras palavras, um modelo com capacidade de consulta pode alcançar desempenho elevado utilizando apenas os exemplos mais informativos. Esse paradigma é motivado por cenários em que há abundância de dados não rotulados e o custo de rotular é alto.

Para implementar o aprendizado ativo, definem-se estratégias de consulta que estimam a utilidade de rotular cada instância disponível. Abordagens comuns incluem amostragem por incerteza (rotular as instâncias nas quais o modelo está menos confiante), seleção por comitê (vários modelos votam nas instâncias mais controversas) e redução de erro esperado.

No contexto de meta-aprendizado para AutoML, o aprendizado ativo é relevante como extensão futura: ao invés de avaliar todos os 60 pipelines em cada novo conjunto de dados, um sistema poderia selecionar ativamente quais pipelines avaliar primeiro com base na incerteza do metamodelo, reduzindo o custo computacional da construção do meta-conjunto. Doucet *et al.* (2025) e Sener e Savarese (2018) exemplificam essa abordagem ao utilizar *embeddings* para guiar a seleção de exemplos informativos no espaço de características — princípio análogo ao uso de *embeddings* de conjuntos de dados para identificar quais avaliações de pipeline são mais informativas para o sistema de recomendação.

2.5 Seleção e estrutura de *pipelines*

Em sistemas AutoML, um *pipeline* de aprendizado de máquina consiste na composição de múltiplos passos de pré-processamento e modelagem que transformam os dados até a predição final. Em geral, pipelines são representados como grafos acíclicos direcionados (DAGs), podendo incluir estruturas paralelas como comitês. Essa flexibilidade permite representar desde um pipeline simples (uma sequência linear de transformação e classificador) até configurações complexas (ex.: três sub pipelines com combinação por votação majoritária).

Entretanto, o número de pipelines possíveis cresce rapidamente com o número de algoritmos e passos disponíveis. Como observado por Schoenfeld, Seppi e Giraud-Carrier (2022), as diversas maneiras de combinar algoritmos em pipelines criam um espaço de busca *não escalonável* de possíveis fluxos a serem considerados. Diante disso, é útil empregar estratégias de pré-seleção ou ranqueamento de pipelines candidatos para priorizar a execução daqueles com maior potencial (especialmente quando recursos computacionais são limitados). Por exemplo, abordagens tradicionais de AutoML, como Auto-sklearn (FEURER *et al.*, 2015) e SmartML (MAHER; SAKR, 2019), tratam o pipeline como uma caixa-preta e utilizam apenas o desempenho observado e a similaridade de meta características do conjunto de dados para ranquear

modelos. Outras soluções simplificam a estrutura do pipeline, por exemplo considerando apenas sequências lineares e usando uma rede LSTM para estimar valor[1].

Em contraste, trabalhos mais recentes exploram explicitamente a estrutura do pipeline. Schoenfeld (2020) propõe um metamodelo baseado em rede neural dinamicamente montada, capaz de modelar DAGs arbitrários do pipeline. Schoenfeld, Seppi e Giraud-Carrier (2022) validam empiricamente essa abordagem criando um grande meta conjunto (cerca de 400.000 instâncias de aproximadamente 4.000 pipelines avaliados em 194 bases) e mostram que metamodelos que consideram metadados granulares de cada pipeline superam aqueles que usam representações simplificadas. Concretamente, eles demonstraram que metamodelos que utilizam toda a estrutura do pipeline fornecem estimativas de desempenho mais precisas, e que ranquear pipelines baseado na similaridade das meta características do conjunto de dados resulta em recomendações superiores às baseadas em estimativas de desempenho absolutas.

Em resumo, a seleção de pipelines em AutoML combina conhecimento do domínio (via meta-características de dados) e exploração da estrutura dos fluxos de processamento. Esse campo de pesquisa continua em desenvolvimento, mas já existe consenso de que considerar explicitamente a granularidade e a estrutura dos pipelines é crucial para sistemas AutoML eficientes e escaláveis.

2.6 Componentes do Arsenal Experimental

Como a metodologia deste trabalho avalia combinações de escalonamento, seleção de atributos e classificação, é necessário explicitar o papel dos operadores que compõem o arsenal experimental. Todos os componentes foram implementados por meio da biblioteca *scikit-learn*, referência consolidada para experimentação reprodutível em aprendizado de máquina com Python (PEDREGOSA *et al.*, 2011).

No estágio de escalonamento, foram considerados três transformadores e uma alternativa sem transformação. O `StandardScaler` centraliza cada atributo pela média e o reescala pelo desvio padrão, tornando os atributos comparáveis em termos de variância. O `MinMaxScaler` reescala os valores para um intervalo fixo, usualmente $[0,1]$. O `RobustScaler` utiliza mediana e intervalo interquartil, sendo menos sensível a valores extremos. Esses operadores são relevantes porque algoritmos baseados em distância, margem ou otimização numérica, como k-NN, SVM e MLP, podem ser fortemente afetados por diferenças de escala entre atributos.

No estágio de seleção ou redução de atributos, foram utilizados PCA, `SelectKBest` e ausência de seleção. A PCA projeta os dados em componentes ortogonais que concentram a maior variância possível, sendo uma técnica clássica de redução de dimensionalidade (JOL-

[1] LSTM: rede neural recorrente que aprende dependências de longo prazo em sequências por meio de um mecanismo de portas que regula o fluxo de informação em uma célula de memória interna Hochreiter e Schmidhuber (1997).

LIFFE, 2002). O `SelectKBest`, neste trabalho, utiliza o critério `f_classif`, baseado no teste F da ANOVA, para manter os atributos mais associados ao alvo; trata-se de uma estratégia de filtragem supervisionada de atributos (GUYON; ELISSEEFF, 2003). A alternativa `None` preserva todos os atributos originais, permitindo avaliar quando a redução dimensional prejudica ou favorece o desempenho.

No estágio de classificação, foram avaliados cinco algoritmos. O RF combina múltiplas árvores de decisão treinadas sobre amostras e subconjuntos de atributos, reduzindo variância e aumentando robustez em dados tabulares (BREIMAN, 2001). A SVM busca hiperplanos de máxima margem e, com kernel RBF, modela fronteiras não lineares (CORTES; VAPNIK, 1995). O k-NN é um método baseado em instâncias que classifica uma nova amostra pela vizinhança mais próxima no espaço de atributos (COVER; HART, 1967). A MLP é uma rede neural feedforward capaz de modelar relações não lineares por camadas ocultas (BISHOP, 2006). Por fim, a DT particiona recursivamente o espaço de atributos por regras de decisão, oferecendo interpretabilidade e baixo custo computacional (QUINLAN, 1986).

2.7 Embeddings de Conjuntos de Dados e Métricas de Ranking

Esta seção apresenta os dois fundamentos diretamente empregados na proposta deste trabalho: as representações vetoriais de conjuntos de dados conhecidas como *embeddings*, utilizadas para caracterizar os conjuntos de dados do meta-conjunto, e as métricas empregadas para avaliar a qualidade de um ranqueamento de pipelines.

2.7.1 Embeddings de Conjuntos de Dados

Uma limitação das meta-características tradicionais é que cada conjunto de dados é representado por um único vetor de estatísticas globais — médias, variâncias, entropia das classes —, o que descarta a variabilidade interna da distribuição dos atributos. Para superar essa limitação, abordagens mais recentes propõem *embeddings* de conjuntos de dados: vetores densos de dimensão fixa que capturam propriedades representativas do conjunto de dados de forma invariante ao número de atributos e instâncias.

Jomaa, Schmidt-Thieme e Grabocka (2021) propõem o Dataset2Vec, um *embedding* neural baseado em arquitetura DeepSet que representa o conjunto de dados como um conjunto hierárquico de pares preditores-alvo. O modelo é treinado com uma tarefa auxiliar de similaridade entre conjuntos de dados e produz vetores de 64 dimensões cujas proximidades no espaço euclidiano correlacionam-se com a similaridade de desempenho de algoritmos. Os autores identificam quatro critérios desejáveis para embeddings de conjuntos de dados, a saber: (D1) independência de esquema — aplicável a qualquer conjunto sem restrição de dimensionalidade; (D2) expressividade — capacidade de distinguir conjuntos com características de

aprendizado distintas; (D3) escalabilidade — calculável sem treinamento para novos conjuntos; (D4) correlação com meta-alvos — os vetores devem predizer desempenho de algoritmos.

Uma alternativa sem necessidade de treinamento consiste nos *embeddings* estatísticos distribucionais: estatísticas calculadas por atributo são agregadas entre atributos por percentis e outras medidas, produzindo um vetor de dimensão fixa. Essa construção permite receber esquemas de tamanhos diferentes sem treinar uma rede de representação. A expressividade e a associação com o desempenho dos pipelines precisam ser avaliadas empiricamente. A abordagem compartilha com o MF2[2] de Feurer, Springenberg e Hutter (2015) o uso de meta-características fixas; essa relação não demonstra superioridade representacional.

2.7.2 Métricas de Avaliação de Ranking

Na tarefa de ranqueamento de pipelines, a qualidade das predições é medida por métricas que comparam a ordenação predita com a ordenação real. As principais métricas utilizadas na literatura de meta-aprendizado são:

Coeficiente de Correlação de Spearman (ρ): mede a correlação monotônica entre os postos atribuídos aos scores preditos e reais. Valores próximos de 1 indicam que o ranking predito preserva a ordem correta dos pipelines; valores próximos de zero indicam ausência de correlação Spearman (1904).

Kendall Tau (τ): mede a fração líquida de pares de pipelines corretamente ordenados. Dado um par (i, j), o par é concordante se o ranking predito e o real concordam sobre qual pipeline é superior; é discordante caso contrário. O valor de τ é a diferença entre pares concordantes e discordantes, normalizada com tratamento de empates (tau-b na implementação) Kendall (1938).

Kendall Tau Ponderado (τ_w): extensão do Kendall Tau que atribui pesos maiores às inversões de ordem que ocorrem no topo do ranking. Implementado em `scipy.stats.weightedtau`, a configuração padrão usa pesos hiperbólicos aditivos $1/(r_i + 1) + 1/(r_j + 1)$ e média de duas ordenações lexicográficas decrescentes dos escores real e predito. Postos menores têm mais peso; a implementação não fornece p-valor.

NDCG (*Normalized Discounted Cumulative Gain*): métrica proveniente da área de recuperação de informação, que pondera a relevância dos itens recuperados pelo logaritmo da posição na lista. Em meta-aprendizado, o NDCG penaliza explicitamente pipelines de alto desempenho recomendados em posições distantes do topo.

A adoção conjunta dessas quatro métricas permite avaliar o sistema tanto em termos de correlação global (Spearman e Kendall Tau) quanto de precisão nas posições de maior impacto

[2] O MF2 é um conjunto de 46 meta-características estáticas — incluindo medidas de *landmarking*, componentes principais (PCA) e proporção de valores ausentes — originalmente proposto por Reif, Shafait e Dengel (2012) e empregado por Feurer, Springenberg e Hutter (2015) para estimar a similaridade entre conjuntos de dados na inicialização de otimização bayesiana de hiperparâmetros.

prático. Nesse segundo grupo, Kendall Tau ponderado e NDCG são métricas complementares: a primeira penaliza inversões pareadas no topo do ranking, enquanto a segunda mede a relevância acumulada das primeiras posições.

2.8 Trabalhos Relacionados

Esta seção apresenta os principais trabalhos relacionados à proposta desta pesquisa, organizados em três eixos temáticos: (i) abordagens para extração de meta-características e representação de conjuntos de dados; (ii) sistemas de recomendação de algoritmos e pipelines de aprendizado de máquina via meta-aprendizado; e (iii) estratégias de avaliação de complexidade de fronteiras de decisão e aprendizado ativo. Ao final, é apresentada uma síntese comparativa que posiciona a presente proposta em relação ao estado da arte.

2.8.1 Representação de Conjuntos de Dados e Meta-características

A qualidade dos metamodelos em sistemas de meta-aprendizado depende diretamente da capacidade de representar conjuntos de dados de forma compacta e informativa. Historicamente, duas correntes principais se desenvolveram: a engenharia de meta-características estáticas e a aprendizagem de meta-características por redes neurais.

Vanschoren *et al.* (2014) introduzem o OpenML, uma plataforma colaborativa que centraliza conjuntos de dados, experimentos e resultados de algoritmos em um repositório público e estruturado. Além de prover acesso unificado a conjuntos de dados anotados, o OpenML define uma infraestrutura para coleta sistemática de metadados — acurácias, tempos de execução e hiperparâmetros utilizados — que viabiliza a construção de meta-conjuntos. A plataforma forneceu as 201 tarefas do acervo histórico deste trabalho; após auditoria, a avaliação principal utiliza 193 tarefas em 165 grupos. Tarefas distintas não correspondem necessariamente a conjuntos independentes.

Schoenfeld, Seppi e Giraud-Carrier (2022) investigam a construção de meta-conjuntos de grande escala para otimização de pipelines, criando uma base com aproximadamente 400 mil instâncias derivadas de 4 mil pipelines avaliados em 194 conjuntos do programa D3M. O trabalho demonstra empiricamente que metamodelos que consideram metadados granulares de toda a estrutura do pipeline superam abordagens que utilizam apenas representações simplificadas. Os autores mostram, ainda, que o ranqueamento baseado em similaridade de meta-características fornece recomendações superiores às estimativas de desempenho absoluto, convergindo diretamente com a abordagem adotada neste TCC.

Jomaa, Schmidt-Thieme e Grabocka (2021) propõem o *Dataset2Vec*, um extrator de meta-features baseado em uma arquitetura DeepSet que representa conjuntos de dados como conjuntos hierárquicos de pares preditores-alvo. O modelo é treinado com uma tarefa auxiliar

de aprendizagem de similaridade entre conjuntos de dados (*dataset similarity learning*), que determina se dois subconjuntos amostrados provêm do mesmo conjunto. Os resultados experimentais com 120 conjuntos UCI para a tarefa de otimização de hiperparâmetros demonstram que as meta-features aprendidas pelo Dataset2Vec superam meta-features estáticas tradicionais (MF1 de Wistuba, Schilling e Schmidt-Thieme (2016) com 22 dimensões; MF2 de Feurer, Springenberg e Hutter (2015) com 46 dimensões) e o *Neural Statistician* (Edwards e Storkey (2017)) em termos de correlação de Spearman com os alvos de desempenho.

O presente trabalho diferencia-se do Dataset2Vec em dois aspectos: (i) utiliza um vetor estatístico de 64 posições, composto por 55 descritores e nove zeros, sem treinamento prévio da representação; e (ii) investiga o *ranqueamento de um arsenal fixo de pipelines*. O vetor admite conjuntos com diferentes números de atributos e pode ser recalculado deterministicamente. A comparação entre k-NN e Random Forest com essa mesma entrada avalia o efeito do preditor; não demonstra vantagem sobre Dataset2Vec, MF2 ou outras representações.

2.8.2 Sistemas de Recomendação de Algoritmos e Pipelines

Schoenfeld (2020) propõem um metamodelo baseado em rede neural dinamicamente configurável, capaz de modelar DAGs arbitrários de pipelines. O sistema representa cada operador do pipeline com uma subrrede específica e combina as representações por uma função de pooling global. Esta abordagem permite estimar o desempenho de configurações de pipeline inéditas sem avaliação direta, tornando a exploração do espaço de busca mais eficiente. A arquitetura supera metamodelos com representações simplificadas de pipeline, reforçando a importância de considerar a estrutura interna dos fluxos de processamento.

Golshanrad *et al.* (2021) apresentam o sistema MEGA (*Meta-learning Ensemble for Genetic Algorithm*), um método de combinação de classificadores que emprega meta-aprendizado e algoritmo genético para selecionar a melhor combinação de classificadores para um conjunto de dados desconhecido. O sistema extrai meta-características dos conjuntos, usa um algoritmo genético para encontrar combinações eficazes e, na fase de inferência, aplica um k-NN ponderado para recomendar combinações ideais. O uso do k-NN como metamodelo de inferência é compatível com a abordagem adotada neste trabalho, onde também se emprega k-NN para predição de rankings de pipelines.

Pereira, Santos e Carvalho (2021) investigam a recomendação de algoritmos de seleção de atributos por meta-aprendizado, modelando a tarefa como um problema supervisionado. O trabalho emprega k-NN, SVM, árvores de decisão e florestas aleatórias como meta-aprendizes, com meta-características extraídas de 28 meta-conjuntos do repositório ASlib. Os autores demonstram que técnicas de redução de dimensionalidade (PCA, seleção por variância, Chi-quadrado, ANOVA-F) permitem reduzir em mais de 80% o número de meta-características sem degradar o desempenho preditivo, evidenciando a robustez de abordagens baseadas em similaridade para recomendação.

Wang, Song e Zhu (2021) propõem um método multi-rótulo de recomendação de algoritmos de classificação baseado em aprendizado por comitê. O modelo mapeia meta-características de 1090 problemas de classificação para o conjunto de algoritmos adequados, combinando múltiplos tipos de meta-características em modelos-base com integração ponderada. Os experimentos demonstram superioridade em métricas de ranking (perda de ordenação e *Precision@m*) sobre modelos individuais, reforçando o valor de abordagens de comitê para recomendação.

Khan *et al.* (2023) descrevem o AutoFE-Sel, sistema de meta-aprendizado para recomendação de algoritmos de seleção de subconjunto de atributos. A abordagem utiliza a métrica EARR (*Adjusted Ratio of Ratios*), que combina acurácia, tempo de execução e número de atributos selecionados para comparar algoritmos. Experimentos com 125 conjuntos de dados e 12 algoritmos candidatos demonstram que o AutoFE-Sel supera abordagens tradicionais (MCFA, IBL-Ranking, Fuzzy-Sim) em acurácia, *hit-ratio* e *F-measure*, atingindo acerto superior a 92%.

2.8.3 Avaliação de Fronteiras de Decisão e Aprendizado Ativo

Varshney e Ramamurthy (2015) utilizam topologia persistente para caracterizar a complexidade das fronteiras de decisão em classificadores supervisionados, construindo complexos simpliciais a partir de amostras com rótulos distintos. Os números de Betti obtidos pela homologia persistente correlacionam-se com o desempenho preditivo dos modelos de SVM, auxiliando na seleção de hiperparâmetros. Embora a abordagem topológica seja distinta da proposta neste TCC, o princípio de usar características intrínsecas dos dados para orientar a seleção de modelos é compartilhado.

Ramamurthy, Varshney e Mody (2018) expandem a análise topológica propondo os complexos *labeled Čech* e *labeled Vietoris-Rips* para estimar a complexidade topológica da fronteira de decisão (DBTC). Experimentos em MNIST, FashionMNIST e CIFAR-10 mostram que a correspondência entre a DBTC do modelo e a do conjunto de dados favorece a seleção de modelos pré-treinados, evidenciando que propriedades estruturais dos dados podem guiar a escolha de algoritmos.

Peng (2020) apresentam uma revisão abrangente sobre meta-aprendizado, sistematizando métodos baseados em otimização, modelo, métrica e inferência Bayesiana. O trabalho discute como o aprendizado meta-episódico permite generalização eficiente para novas tarefas com dados rotulados limitados, especialmente em cenários de *few-shot learning* (aprendizado a partir de pouquíssimos exemplos rotulados por classe), formalizando a notação de meta-tarefas $\tau_i \sim \mathcal{P}(\mathcal{T})$ com conjuntos de suporte $\mathcal{D}_i^s$ e consulta $\mathcal{D}_i^q$.

Doucet *et al.* (2025) propõem o método TCM, que combina amostragem baseada em diversidade e incerteza para aprendizado ativo. O TCM realiza uma transição gradual de *TypiClust* — que seleciona exemplos representativos por clustering em embeddings auto-supervisionados — para *Margin Sampling*, focado na incerteza do modelo. Os autores demonstram superiori-

dade sobre BADGE, Coreset e ProbCover em CIFAR-10, CIFAR-100 e ISIC2019, evidenciando o valor de combinar diversidade e incerteza na seleção de instâncias informativas. A utilização de embeddings para identificar exemplos representativos é análoga ao uso de embeddings de conjuntos de dados neste trabalho para identificar conjuntos similares no espaço de meta-aprendizado.

2.8.4 Síntese Comparativa

A Tabela 2 sintetiza os principais trabalhos relacionados em relação a quatro dimensões: tipo de representação dos dados, tarefa de meta-nível, tamanho do meta-conjunto e método de avaliação utilizado.

Tabela 2 – Comparativo entre trabalhos relacionados e a proposta deste TCC

Trabalho	Representação	Tarefa Meta-nível	Meta-conjunto	Avaliação
Schoenfeld et al. (2022)	Estrutura do pipeline (DAG)	Estimativa de desempenho	$\sim$400 k instâncias	Correlação de Spearman
Dataset2Vec (2021)	Embedding neural (DeepSet)	Otimização de hiperparâmetros	120 conjuntos UCI	Spearman (ranqueamento)
MEGA (2020)	Meta-características estáticas	Recomendação de comitês	Múltiplos conjuntos	Acurácia
AutoFE-Sel (2021)	Meta-características estáticas	Seleção de atributos	125 conjuntos	EARR, hit-ratio
Wang et al. (2021)	Meta-características multi-tipo	Recomendação multi-rótulo	1090 conjuntos	Ranking loss, Prec@m
Este TCC	**embedding distribucional 64D**	**Ranqueamento de pipelines**	**193 tarefas / 165 grupos / 60 pipelines**	**Spearman, Kendall (τ, τ_w), NDCG**

Fonte: Autoria própria (2026).

A síntese posiciona a proposta em três aspectos: (i) ranqueamento de pipelines completos; (ii) uso conjunto de Kendall ponderado, NDCG e regret para examinar ordenação e utilidade das recomendações; e (iii) diagnóstico exploratório da qualidade por tarefa e de sua associação com tamanho, dimensionalidade, balanceamento, atributos constantes e distância ao vizinho. A análise usa grupos para reduzir o peso de tarefas repetidas e não estabelece causas das falhas observadas.

A escolha de uma representação estatística distribucional, referida ao longo do trabalho como embedding distribucional por produzir um vetor denso de dimensão fixa, foi motivada por dificuldades de compatibilidade no ambiente original e pelo objetivo de estabelecer uma referência determinística e auditável. A escolha não depende de uma afirmação permanente sobre a disponibilidade de versões do TensorFlow. Diferentemente de embeddings neurais como o Dataset2Vec, essa representação não é aprendida por otimização de uma função objetivo; ela se aproxima do MF2 de Feurer et al. (2015) em termos de engenharia de meta-características, mas captura distribuições de meta-features por atributo em vez de apenas estatísticas globais do conjunto de dados.

2.9 Avaliação Contemporânea de AutoML e Meta-aprendizado

Três eixos complementares orientam a atualização: representação, recomendação e avaliação. No primeiro, Hollmann *et al.* (2025) apresentam TabPFN, um modelo fundacional tabular que exemplifica reutilização de conhecimento entre problemas. Sua tarefa de predição

difere do ranqueamento de um arsenal fixo; seus resultados não são comparação numérica direta.

No eixo de recomendação, Baratchi *et al.* (2024) distinguem espaço de busca, estratégia e avaliação. Esse enquadramento separa representação, metamodelo e candidatos disponíveis. Um arsenal fixo facilita comparação controlada, mas limita conclusões sobre espaços de hiperparâmetros mais amplos.

No eixo de avaliação, Gijsbers *et al.* (2024) apresentam AMLB, um benchmark extensível que considera desempenho, custo e falhas. Essa perspectiva motiva explicitar resultados ausentes e protocolos. Sua aplicação aqui é uma decisão metodológica, não um resultado transferido do AMLB.

Goldblum *et al.* (2024) discutem os pressupostos dos teoremas No Free Lunch e os vieses de problemas reais. O teorema clássico não demonstra que todos os métodos tenham desempenho equivalente em benchmarks práticos, nem garante ganho de um recomendador específico. O ganho precisa ser medido no domínio de interesse.

3 MATERIAIS E MÉTODOS

Este capítulo descreve os dados, a reconstrução dos escores de pipelines e a avaliação dos metamodelos. O protocolo distingue os dados brutos usados na validação dos classificadores da meta-descrição da tarefa rotulada. A reconstrução integral substitui a produção histórica de escores na avaliação principal; os artefatos anteriores são preservados para comparação controlada.

3.1 Materiais e Fonte dos Dados

Os dados provêm de 201 tarefas OpenML (VANSCHOREN *et al.*, 2014) do acervo original. Os metadados oficiais identificam tarefa, versão do dataset e alvo; os arquivos brutos ficam no cache local OpenML, e seus hashes integram o catálogo. Utiliza-se o alvo especificado pela tarefa, confirmado como igual ao padrão do dataset nesta coleta. Não houve falha de carregamento.

Os critérios de inclusão são classificação supervisionada, 500 a 10.000 exemplos, ao menos duas classes, pelo menos cinco observações por classe e atributos tabulares disponíveis após remover colunas de data/hora. Os critérios não usam desempenho dos classificadores ou do ranqueamento. Permanecem 193 tarefas elegíveis em 165 grupos; o catálogo registra as oito exclusões por suporte de classe insuficiente, nomes, links, tamanho, atributos, classes, balanceamento e proporção de valores ausentes.

Tarefas distintas podem representar o mesmo dataset ou versões relacionadas. Os grupos anteriores, formados por nomes repetidos ou atributos processados idênticos, são preservados e conferidos contra IDs e fingerprints dos atributos brutos. A atribuição de grupos não mudou nesta reconstrução. Essa regra é conservadora, mas não assegura detectar todas as famílias com nomes e transformações diferentes. A tarefa 363713 já integrava o acervo e não é tratada como holdout externo.

3.1.1 Ambiente Computacional

A execução usa Python 3.14.2, NumPy 2.4.3, pandas 3.0.1, SciPy 1.17.1 e scikit-learn 1.8.0. O computador local dispõe de processador Intel Core i5-9400F, com seis núcleos lógicos. A reconstrução utiliza quatro processos inicialmente e seis após retomada dos checkpoints em tarefas diferentes, com uma thread BLAS e um job por classificador em cada processo. As versões efetivas, configurações, ajustes operacionais e hashes constam dos manifestos; a limitação de paralelismo controla a utilização de recursos sem subamostrar observações.

3.2 Fase 1: Escores em Dados Brutos

Para cada tarefa, uma validação estratificada de cinco folds usa embaralhamento e semente 42. Cada observação participa do teste uma única vez e do treino nos demais folds. Os índices são gerados uma vez por tarefa e compartilhados por todos os pipelines. Não existe subamostra exclusiva da SVM: os cinco classificadores recebem as mesmas linhas de treino e teste em cada fold.

O tratamento numérico estima a mediana exclusivamente no treino, preservando atributos vazios. Nos atributos categóricos, valores ausentes são convertidos deterministicamente em um marcador; um codificador ordinal é ajustado no treino, atribuindo -1 a categorias desconhecidas no teste. Escalonadores e seletores também são ajustados apenas no treino. O teste recebe somente as transformações ajustadas, sem usar seus rótulos para selecionar atributos ou estimar parâmetros.

As transformações comuns são calculadas uma vez por fold e combinação e reutilizadas pelos classificadores que recebem exatamente a mesma entrada. Essa otimização não compartilha ajuste entre folds e não muda os algoritmos. A auditoria verifica cobertura de linhas, ausência de interseção treino/teste e amostras equivalentes entre classificadores.

3.2.1 Arsenal de 60 Pipelines

O arsenal cruza quatro escalonadores (StandardScaler, MinMaxScaler, RobustScaler e ausência), três seletores (PCA, SelectKBest por ANOVA e ausência) e cinco classificadores. Os seletores usam $q = \min(10, \max(1,P-1),N_{treino})$ componentes ou atributos, respeitando dimensões disponíveis. PCA usa solver automático e semente 42, controlando a parte aleatória não fixada no código histórico.

Os classificadores são: (i) Random Forest com 100 árvores; (ii) SVM RBF com $C = 1$, gamma scale e sem limite de subamostra; (iii) k-NN com cinco vizinhos uniformes; (iv) MLP com camadas 64 e 32, otimizador Adam e até 200 iterações; e (v) árvore de decisão com profundidade máxima 10. Usa-se semente 42 nos componentes estocásticos. Demais parâmetros são os padrões da versão registrada da biblioteca, exportados para auditoria. Não se otimizam os hiperparâmetros desse arsenal nesta comparação.

3.2.2 Métricas, Avisos e Resultados Ausentes

São calculados acurácia balanceada e F1 macro no teste de cada fold. O alvo do metamodelo é a média de acurácia balanceada dos cinco folds, não uma média de subconjunto de folds bem-sucedidos. Se qualquer ajuste falhar, o alvo desse par tarefa/pipeline fica ausente. Médias, desvios amostrais, tempos, estados, erros e avisos são registrados separadamente.

Avisos de convergência, especialmente no MLP, são preservados como evidência do orçamento finito de treinamento. Eles não são ocultados nem descritos como convergência garantida. Os escores resultantes caracterizam os modelos com o orçamento fixado. No total, a execução contempla 57900 ajustes para 11580 posições de escore na matriz final.

3.3 Representação Estatística das Tarefas

A representação é um vetor determinístico, sem treinamento neural ou otimização de função objetivo. Para cada atributo numérico após codificação da tarefa, calculam-se média, desvio padrão populacional acrescido de 10^{-8}, mínimo, máximo, mediana, assimetria, curtose de Fisher e correlações de Pearson e Spearman com o alvo codificado. Cada um dos nove descritores é agregado entre atributos por mínimo, percentil 25, média, percentil 75 e máximo: $9 \times 5 = 45$ componentes.

Dez propriedades globais completam o vetor: $\log(1+N)$, $\log(1+P)$, número de classes, proporções majoritária e minoritária, entropia das proporções acrescidas de 10^{-8}, proporção de atributos constantes, média da correlação absoluta entre atributos com diagonal zerada, média das proporções de valores únicos e $P/(N + 10^{-8})$. A média da matriz de correlação inclui os zeros da diagonal no denominador P^2. Concatenam-se 55 descritores e nove zeros; não há truncamento com dimensão 64. Valores não finitos recebem `nan_to_num` e aplica-se norma L2, preservando vetor nulo.

A meta-descrição utiliza a tarefa rotulada completa, disponível no cenário de recomendação, e é calculada separadamente do ajuste dos classificadores em folds. Ela não usa predições ou escores de teste. Portanto, o estudo não cobre consulta sem rótulos e não trata essa extração global de descritores como uma transformação do classificador dentro da CV. As correlações com alvos nominais multiclasses dependem de codificação arbitrária. O vetor estatístico é distinto de uma representação neural aprendida como Dataset2Vec (JOMAA; SCHMIDT-THIEME; GRABOCKA, 2021).

3.4 Fase 2: Predição e Avaliação por Grupos

O k-NN estima a acurácia dos 60 pipelines pela média dos vizinhos ponderada pelo inverso da distância euclidiana:

$$\hat{A}(P_j) = \frac{\sum_i w_i A_{i,j}}{\sum_i w_i}, \qquad w_i = \frac{1}{\|\mathbf{x}_{novo} - \mathbf{x}_i\|_2 + 10^{-8}}. \tag{1}$$

O comparador Random Forest meta é um regressor multi-saída nativo com 200 árvores, mínimo de duas observações por folha, max features 1,0 e semente 42. As baselines são média global de escores por pipeline apenas no treino e ranking aleatório por escores uniformes

com semente 42 acrescida do fold. Avalia-se também k-NN com padronização de dimensões ajustada exclusivamente no treino.

Usa-se GroupKFold externo com cinco divisões, shuffle e semente 42. Dentro do treino externo, quatro divisões por grupos selecionam $k \in \{1,3,5,7,10\}$ pela média de Kendall ponderado por grupo, escolhendo o menor k em empate. Teste externo não participa da escolha de k, padronização ou imputação de alvos. As divisões têm grupos disjuntos em todos os níveis.

Resultados ausentes no treino meta são imputados pela mediana de cada pipeline. Colunas inteiramente ausentes no treino são excluídas da avaliação correspondente no teste. Escores reais ausentes no teste nunca são imputados para calcular qualidade do ranking. Correlações indefinidas permanecem como NaN com estado explícito, mantendo NDCG e regret quando calculáveis.

3.4.1 Métricas de Ranqueamento

Spearman mede associação de postos. Kendall tau-b trata empates, com

$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_x)(C + D + T_y)}}, \tag{2}$$

onde C,D são pares concordantes e discordantes e T_x,T_y contam empates exclusivos. Kendall ponderado padrão da SciPy usa pesos hiperbólicos aditivos $1/(r_i + 1) + 1/(r_j + 1)$ e média de duas ordenações lexicográficas decrescentes dos escores real e predito; sua implementação não fornece p-valor.

NDCG usa ganho linear de acurácia balanceada e desconto logarítmico, conforme a implementação do scikit-learn:

$$\mathrm{NDCG}\,@K = \frac{\mathrm{DCG}\,@K}{\mathrm{IDCG}\,@K}, \qquad \mathrm{DCG}\,@K = \sum_{i=1}^{K} \frac{rel_i}{\log_2(i+1)}. \tag{3}$$

Reportam-se NDCG completo e NDCG@5. Regret@1 é a diferença para a melhor acurácia real disponível ao recomendar o primeiro pipeline; Regret@5 considera o melhor entre os cinco primeiros. Empates recebem tratamento médio em NDCG e ordem estável de colunas em regret. As métricas são complementares: NDCG elevado não equivale a recuperação exata do top-5.

3.4.2 Comparação Controlada e Diagnóstico

Executam-se três condições com as mesmas tarefas, grupos e folds externos: matrizes históricas; escores reconstruídos com vetores históricos; e escores e vetores reconstruídos. As entradas usam precisão float32 em todas as condições, como no armazenamento histórico, evi-

tando mudar a resolução dos empates somente na condição nova. Os valores originais reconstruídos em float64 são preservados. A comparação pareada examina as mesmas tarefas/grupos avaliáveis nas duas condições. Ela distingue parte do efeito da representação, mas não isola causalmente somente a imputação, pois também mudam a codificação por fold, a amostra da SVM e o controle aleatório da PCA.

Calculam-se médias dentro dos grupos e depois entre grupos. Intervalos descritivos de 95% usam 2.000 reamostragens de grupos, com semente 42; a sobreposição dos treinos limita a interpretação inferencial. O diagnóstico usa cinco associações de Spearman por grupo (tamanho, atributos, proporção majoritária, atributos constantes e distância ao vizinho), com ajuste Benjamini–Hochberg e sem atribuição causal.

3.5 Reprodutibilidade e Delimitação

Arquivos separados preservam parâmetros, versões, hashes de dados e código, predições, métricas, índices e estados de cada ajuste. Checkpoints por tarefa permitem retomar sem misturar execuções de configurações distintas. Dados brutos permanecem no cache local; as evidências e matrizes agregadas são versionadas.

O estudo continua retrospectivo, com consulta rotulada e arsenal fixo. Não houve busca exaustiva de hiperparâmetros ou coleta de teste externa após o desenvolvimento. O piloto anterior de 180 avaliações permanece separado. Essas limitações delimitam as conclusões, mesmo após concluir a reconstrução integral da Fase 1.

4 EXPERIMENTOS E RESULTADOS

Este capítulo apresenta a reconstrução integral dos escores da Fase 1 e a repetição da avaliação dos metamodelos. A comparação usa as mesmas tarefas, grupos e partições da referência histórica revisada; por isso, permite avaliar a mudança sem confundi-la com a alteração anterior de LOO por tarefa para validação por grupos. A avaliação continua retrospectiva sobre um acervo previamente explorado.

4.1 Reconstrução Integral da Fase 1

A auditoria dos dados brutos preservou 193 tarefas elegíveis, 179 nomes e 165 grupos. As oito exclusões por suporte insuficiente de classe permanecem documentadas. Não houve falha de carregamento ou mudança entre o alvo oficial da tarefa e o alvo padrão disponível no dataset. A identificação de grupos foi preservada, permitindo usar os mesmos folds externos na comparação.

Foram executados 57900 ajustes de classificadores, correspondentes a 193 tarefas, 60 pipelines e cinco folds estratificados por tarefa. Para todos os classificadores, inclusive SVM, foram usadas as mesmas linhas de treino e teste. A mediana numérica, o codificador categórico, os escalonadores e os seletores foram ajustados exclusivamente no treino de cada fold. O teste recebeu apenas as transformações já ajustadas. Transformações idênticas foram reutilizadas entre classificadores dentro do mesmo fold, sem compartilhar ajustes entre folds.

O processo registrou 0 falhas de ajuste, 0 escores agregados ausentes e 7703 avisos de convergência. Avisos de convergência são preservados como limitação do orçamento fixo, sobretudo do MLP com até 200 iterações; não são convertidos em convergência bem-sucedida. Um escore médio só é disponibilizado se os cinco folds foram avaliados. A matriz reconstruída possui 11580 posições de desempenho.

Nos pares tarefa/pipeline com escore observado nas duas versões, a variação média de acurácia balanceada dos classificadores da Fase 1, em pontos percentuais, foi: árvore de decisão: $-0{,}84$ p.p.; MLP: $-1{,}04$ p.p.; Random Forest: $-1{,}67$ p.p.; SVM: $-1{,}02$ p.p.; k-NN: $-1{,}65$ p.p.. Trata-se de uma média descritiva por par tarefa/pipeline, sem imputar os escores históricos ausentes ou atribuir peso igual aos grupos. Esses valores caracterizam a revisão da estimativa de desempenho dos classificadores; não devem ser confundidos com as métricas de ranqueamento dos metamodelos da Fase 2.

A validação dos artefatos verificou ausência de sobreposição entre treino e teste, cobertura de todas as linhas uma vez no teste e igualdade de amostras entre os 60 pipelines. Configuração, versões, hashes e índices de cada fold foram preservados em arquivos separados. Isso atende à reconstrução antes pendente; os escores históricos permanecem disponíveis para comparação, sem substituição silenciosa.

4.2 Comparação Controlada das Condições

Três condições foram avaliadas nas mesmas tarefas, grupos e partições externas: (i) escores e vetores históricos; (ii) escores reconstruídos com vetores históricos; e (iii) escores reconstruídos com vetores recalculados dos dados brutos. O segundo caso mantém a representação fixa para examinar o efeito dos novos alvos; o terceiro constitui a avaliação principal. As entradas das três condições usam precisão float32, como as matrizes históricas, preservando a mesma resolução numérica para tratar empates; os escores reconstruídos de origem permanecem em float64 nos artefatos da Fase 1. Em todos os casos, o ajuste de k e da padronização ocorre somente no treino interno.

A Tabela 3 apresenta a comparação de Kendall ponderado. As médias de cada condição usam os grupos com métrica definida; a diferença é calculada de forma pareada, apenas com tarefas e grupos avaliáveis em ambas. Assim, a diferença pareada não precisa coincidir exatamente com a subtração de duas médias calculadas com suportes distintos. Os intervalos descritivos completos e as três condições estão nos CSVs.

Tabela 3 – Comparação da referência revisada com a reconstrução integral

Método	τ_w histórico	τ_w reconstruído	Diferença pareada
Aleatório	$0{,}0024$	$0{,}0012$	$-0{,}0003$
Média global	$0{,}3690$	$0{,}4011$	$0{,}0024$
k-NN ajustado	$0{,}3995$	$0{,}4280$	$-0{,}0093$
k-NN padronizado	$0{,}4138$	$0{,}4539$	$0{,}0090$
Random Forest	$0{,}4309$	$0{,}4768$	$0{,}0059$

Fonte: Autoria própria (2026)..

O k-NN apresentou $\tau_w = 0{,}3995$ com escores históricos e $\tau_w = 0{,}4280$ após reconstrução completa; Random Forest passou de $0{,}4309$ para $0{,}4768$. Esses resultados caracterizam a mudança no benchmark sob partições equivalentes. Não isolam causalmente apenas a imputação: também mudam a codificação por fold, a amostra da SVM, a semente explícita da PCA e, na condição principal, a recomputação dos vetores. A análise com vetor histórico fixo ajuda a distinguir o efeito dos escores daquele da representação. Os próprios rankings reais são recalculados e a cobertura pode mudar quando pipelines antes ausentes passam a ter escore; portanto, a diferença não isola ganho de capacidade preditiva sob uma única verdade de referência e um conjunto idêntico de itens avaliáveis.

Nos casos avaliáveis em ambas as versões, a mudança pareada de Kendall ponderado foi $-0{,}0093$ para k-NN, com intervalo descritivo $[-0{,}0282; 0{,}0092]$ em 149 grupos, e $0{,}0059$ para Random Forest, com intervalo $[-0{,}0085; 0{,}0202]$ em 151 grupos. O intervalo da mudança do k-NN ajustado abrange zero. O intervalo da mudança do Random Forest abrange zero. Assim, o

aumento das médias gerais não deve ser interpretado isoladamente como melhoria da predição: também mudou o conjunto de casos com correlação definida.

O antigo valor de aproximadamente $0{,}5222$ para k-NN no LOO por tarefa não é a referência controlada desta seção. Ele usava outro protocolo e potencialmente mantinha tarefas relacionadas no treino; compará-lo diretamente aos resultados atuais atribuiria à Fase 1 diferenças de desenho da avaliação.

4.3 Avaliação Principal dos Metamodelos

A Tabela 4 resume a avaliação dos metamodelos sobre a matriz reconstruída. O k-NN teve correlações definidas em 177 tarefas de 149 grupos. Os valores de k selecionados nos cinco treinos externos foram 5, 10, 10, 10, 10. Casos de correlação indefinida continuam contabilizados nos arquivos; NDCG e regret são preservados quando calculáveis.

Tabela 4 – Metamodelos sobre escores reconstruídos: médias por grupo

Método	Spearman	τ_w	NDCG@5	Regret@1	Tarefas/grupos (τ_w)
Aleatório	$-0{,}0114$	$0{,}0012$	$0{,}8843$	$0{,}0785$	179/151
Média global	$0{,}4277$	$0{,}4011$	$0{,}9522$	$0{,}0260$	179/151
k-NN ajustado	$0{,}4897$	$0{,}4280$	$0{,}9502$	$0{,}0336$	177/149
k-NN padronizado	$0{,}5148$	$0{,}4539$	$0{,}9533$	$0{,}0259$	179/151
Random Forest	$0{,}5293$	$0{,}4768$	$0{,}9632$	$0{,}0207$	179/151

Fonte: Autoria própria (2026)..

A diferença pareada Random Forest menos k-NN em Kendall ponderado foi $0{,}0515$, com intervalo descritivo de 95% $[0{,}0255; 0{,}0771]$. O intervalo descritivo sugere vantagem do Random Forest sobre o k-NN neste acervo. A conclusão é restrita ao acervo e ao protocolo; o Random Forest tem hiperparâmetros fixos e não houve comparação exaustiva de metamodelos. A Figura 1 mostra os intervalos das médias por grupo.

O regret@1 foi $0{,}0336$ para k-NN, $0{,}0207$ para Random Forest e $0{,}0260$ para média global. A baseline aleatória apresentou NDCG@5 de $0{,}8843$. Isso reforça a necessidade de interpretar NDCG com as correlações e o regret: relevâncias próximas podem gerar NDCG alto sem recuperação exata do top-5. Kendall ponderado enfatiza inversões de maior peso, enquanto NDCG acumula relevância com desconto logarítmico.

4.4 Diagnóstico de Falhas

O k-NN ajustado apresentou 13 tarefas com Kendall ponderado não positivo e 16 com correlação indefinida. Foram registradas 14 tarefas com escores reais constantes e 2 com predição constante e escores reais variáveis. Uma correlação indefinida não é promovida a acerto

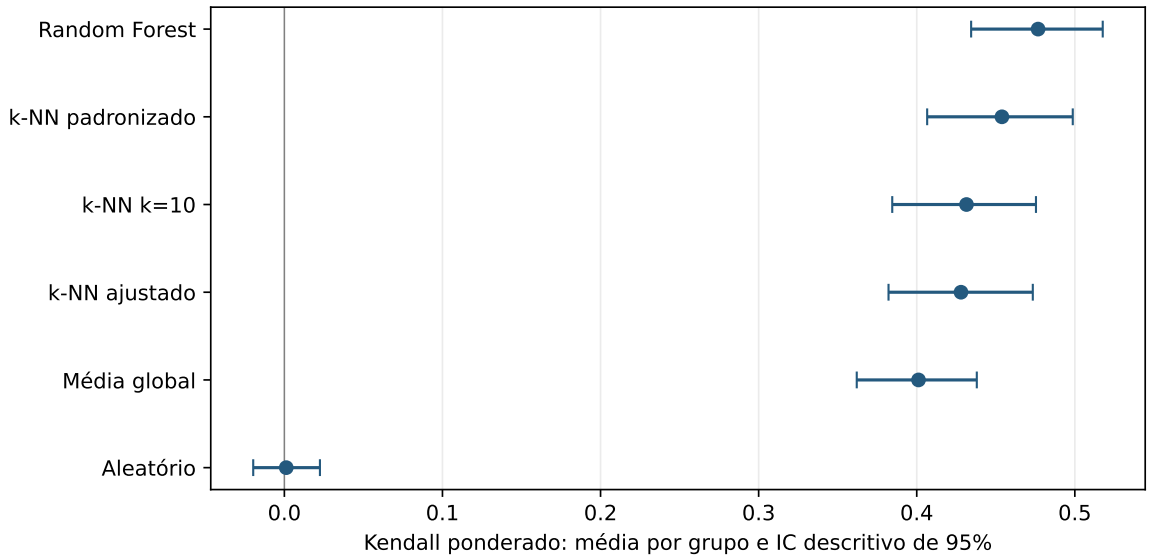


Figura 1 – Kendall ponderado após reconstrução da Fase 1

Fonte: Autoria própria (2026)..

nem convertida em zero. O diagnóstico liga cada task a tamanho, dimensionalidade, balanceamento, atributos constantes, distância ao vizinho de treino, predições e estado de avaliação. Entre as menores correlações definidas estão: tarefa 9976 ($\tau_w = -0{,}4184$, $N = 2600$, $P = 500$, proporção majoritária $0{,}5000$); tarefa 3512 ($\tau_w = -0{,}3760$, $N = 600$, $P = 60$, proporção majoritária $0{,}1667$); tarefa 363159 ($\tau_w = -0{,}3330$, $N = 4531$, $P = 1$, proporção majoritária $0{,}0603$). A inspeção permite reproduzir os casos, sem atribuir automaticamente suas falhas a uma característica isolada. Nenhuma das cinco associações exploratórias permaneceu abaixo de $q = 0{,}05$ após ajuste Benjamini–Hochberg. Essas associações não demonstram causalidade nem explicam isoladamente a variabilidade.

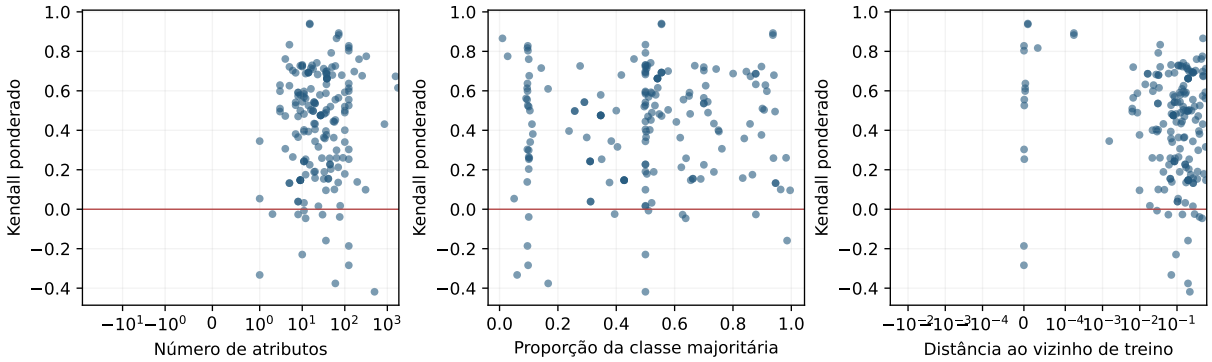


Figura 2 – Diagnóstico do k-NN com escores reconstruídos

Fonte: Autoria própria (2026)..

4.5 Discussão e Limitações

A reconstrução corrige os dois problemas identificados na produção dos escores: estimar imputação antes da CV e usar amostra exclusiva da SVM. O controle também inclui codifica-

ção e seleção ajustadas no treino. A inclusão desses cuidados não implica aumento necessário das métricas; o objetivo é estimar desempenho sob condições comparáveis.

Permanecem como limites: avaliação retrospectiva, agrupamento conservador que pode não detectar todas as famílias, codificação ordinal de variáveis nominais, correlações de rótulos multiclasses dependentes de sua codificação e orçamento fixo de treinamento. A auditoria registra 30 tarefas somente categóricas e 18 com nomes sugestivos de identificadores ou caminhos. Esses indicadores exigem interpretação de escopo e não demonstram vazamento por si só; não foram usados para excluir tarefas após observar resultados. A representação descreve um conjunto rotulado completo e não cobre consulta sem rótulos. Intervalos de bootstrap dos grupos são descritivos, pois treinos de folds se sobrepõem. A comparação de metamodelos com o mesmo vetor não substitui uma ablação de representações.

O piloto anterior de 180 avaliações de hiperparâmetros permanece como evidência exploratória separada. O arsenal principal foi mantido em 60 candidatos para comparar protocolos e metamodelos sob espaço controlado. Expandir todo o arsenal, otimizar os metamodelos e avaliar conjuntos externos coletados após o desenvolvimento são próximos passos, sem tratar resultados de outros benchmarks como comparações numéricas equivalentes (GIJSBERS *et al.*, 2024; BARATCHI *et al.*, 2024).

5 CONCLUSÃO

Este trabalho desenvolveu e avaliou uma infraestrutura de meta-aprendizado para ranquear pipelines de classificação com descritores estatísticos de conjuntos rotulados. A auditoria das tarefas e a reconstrução da Fase 1 permitiram revisar resultados e conclusões com maior controle experimental.

5.1 Síntese dos Resultados

O acervo histórico continha 201 tarefas. Os critérios de qualidade delimitaram 193 tarefas em 165 grupos, sobre as quais foram executados 57900 ajustes dos 60 pipelines em cinco folds. Todas as etapas ajustáveis de pré-processamento usaram somente treino, e a SVM recebeu as mesmas amostras dos demais classificadores. Os avisos e as falhas foram documentados, sem substituir escores ausentes por resultados de teste.

Na avaliação principal, o Kendall ponderado médio por grupo foi $0{,}4280$ para k-NN, $0{,}4768$ para Random Forest e $0{,}4011$ para média global. A diferença Random Forest menos k-NN foi $0{,}0515$, com intervalo descritivo $[0{,}0255; 0{,}0771]$. O intervalo descritivo sugere vantagem do Random Forest sobre o k-NN neste acervo. O diagnóstico encontrou 13 tarefas com Kendall ponderado não positivo e 16 com correlação indefinida.

A comparação com escores históricos usou as mesmas tarefas e partições, distinguindo a reconstrução de escores da recomputação da representação. Os valores de LOO por tarefa divulgados inicialmente não constituem uma comparação direta com a validação revisada por grupos. A melhoria do protocolo deve ser distinguida de qualquer alteração numérica de desempenho.

Na comparação pareada com a referência revisada, a mudança de Kendall ponderado foi $-0{,}0093$ para k-NN e $0{,}0059$ para Random Forest. O intervalo da mudança do k-NN ajustado abrange zero. O intervalo da mudança do Random Forest abrange zero. A elevação das médias gerais, calculadas sobre suportes diferentes, não estabelece melhoria geral da predição.

5.2 Atendimento dos Objetivos

O primeiro objetivo foi atendido pela construção e reconstrução auditável do metaconjunto, com dados, configurações, escores e falhas rastreáveis. O segundo foi atendido pela implementação e avaliação de preditores de ranking com ajuste interno e grupos externos separados. O ganho depende da métrica e do comparador; não se conclui adequação uniforme para todos os problemas.

5.3 Limitações e Perspectivas

A representação determinística exige rótulos na consulta e usa codificações nominais que limitam a interpretação de algumas correlações. A avaliação continua retrospectiva, os grupos podem não identificar todas as versões relacionadas, os hiperparâmetros dos classificadores e do Random Forest meta foram mantidos fixos e o orçamento de MLP pode produzir avisos de convergência. Os intervalos de bootstrap são descritivos devido à sobreposição dos treinos.

A reconstrução integral da Fase 1 foi concluída nesta etapa; deixa de ser uma pendência do trabalho. As próximas etapas são ampliar o arsenal de hiperparâmetros, comparar representações sob o mesmo protocolo, avaliar orçamento e convergência e validar em dados externos coletados após o desenvolvimento. O piloto anterior de hiperparâmetros permanece uma análise exploratória separada.

REFERÊNCIAS

BARATCHI, M. *et al.* Automated machine learning: past, present and future. **Artificial Intelligence Review**, v. 57, p. 122, 2024. Disponível em: https://link.springer.com/article/10.1007/s10462-024-10726-1.

BISHOP, C. M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006.

BRAZDIL, P. *et al.* **Metalearning: Applications to Data Mining**. [*S.l.*]: Springer, 2008. (Cognitive Technologies).

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

COHN, D.; ATLAS, L.; LADNER, R. Improving generalization with active learning. **Machine Learning**, v. 15, p. 201–221, 1994.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273–297, 1995.

COVER, T. M.; HART, P. E. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967.

DOMINGOS, P. **O algoritmo mestre: como a busca pelo algoritmo de machine learning definitivo recriará nosso mundo**. [*S.l.*]: Novatec Editora, 2017.

DOUCET, P. *et al.* Bridging diversity and uncertainty in active learning with self-supervised pre-training. 2025. Disponível em: https://arxiv.org/abs/2403.03728.

DUA, D.; GRAFF, C. **UCI Machine Learning Repository**. 2019. University of California, Irvine, School of Information and Computer Sciences. Disponível em: https://archive.ics.uci.edu/ml.

EDWARDS, H.; STORKEY, A. Towards a neural statistician. *In*: **International Conference on Learning Representations (ICLR)**. [*S.l.*: *s.n.*], 2017.

FEURER, M. *et al.* Efficient and robust automated machine learning. *In*: **Advances in Neural Information Processing Systems 28 (NIPS 2015)**. [*S.l.*]: Curran Associates, Inc., 2015. p. 2962–2970.

FEURER, M.; SPRINGENBERG, J. T.; HUTTER, F. Initializing bayesian hyperparameter optimization via meta-learning. *In*: **Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence**. Austin, Texas, USA: AAAI Press, 2015. p. 1128–1135.

GIJSBERS, P. *et al.* AMLB: an AutoML benchmark. **Journal of Machine Learning Research**, v. 25, n. 101, p. 1–65, 2024. Disponível em: https://www.jmlr.org/papers/v25/22-0493.html.

GOLDBLUM, M. *et al.* Position: The no free lunch theorem, kolmogorov complexity, and the role of inductive biases in machine learning. *In*: **Proceedings of the 41st International Conference on Machine Learning**. PMLR, 2024. (Proceedings of Machine Learning Research, v. 235), p. 15788–15808. Disponível em: https://proceedings.mlr.press/v235/goldblum24a.html.

GOLSHANRAD, P. *et al.* Mega: Predicting the best classifier combination using meta-learning and a genetic algorithm. **Intelligent Data Analysis**, v. 25, n. 6, p. 1547–1563, 2021. Disponível em: https://journals.sagepub.com/doi/abs/10.3233/IDA-205494.

GUYON, I.; ELISSEEFF, A. An introduction to variable and feature selection. **Journal of Machine Learning Research**, v. 3, p. 1157–1182, 2003.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997.

HOLLMANN, N. *et al.* Accurate predictions on small data with a tabular foundation model. **Nature**, v. 637, p. 319–326, 2025. Disponível em: https://doi.org/10.1038/s41586-024-08328-6.

JOLLIFFE, I. T. **Principal Component Analysis**. 2. ed. New York: Springer, 2002.

JOMAA, H. S.; SCHMIDT-THIEME, L.; GRABOCKA, J. Dataset2vec: Learning dataset meta-features. **Data Mining and Knowledge Discovery**, v. 35, n. 3, p. 964–985, 2021.

KENDALL, M. G. A new measure of rank correlation. **Biometrika**, v. 30, n. 1/2, p. 81–93, 1938.

KHAN, I. *et al.* Autofe-sel: A meta-learning based methodology for recommending feature subset selection algorithms. **KSII Transactions on Internet and Information Systems**, v. 17, p. 1773–1793, 07 2023.

LIPPMANN, R.; CAMPBELL, W.; CAMPBELL, J. An overview of the DARPA data driven discovery of models (D3M) program. *In*: **29th Conference on Neural Information Processing Systems (NIPS)**. Barcelona, Spain: [*s.n.*], 2016.

MAHER, M.; SAKR, S. SmartML: A meta learning-based framework for automated selection and hyperparameter tuning for machine learning algorithms. *In*: **Proceedings of the 22nd International Conference on Extending Database Technology (EDBT 2019)**. Lisboa, Portugal: [*s.n.*], 2019. p. 554–557.

OLSON, R. S. *et al.* Automating biomedical data science through tree-based pipeline optimization. *In*: **Applications of Evolutionary Computation**. [*S.l.*]: Springer, 2016. p. 123–137.

PEDREGOSA, F. *et al.* Scikit-learn: Machine learning in python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PENG, H. A comprehensive overview and survey of recent advances in meta-learning. **CoRR**, abs/2004.11149, 2020. Disponível em: https://arxiv.org/abs/2004.11149.

PEREIRA, G. T.; SANTOS, M. R. dos; CARVALHO, A. C. P. de Leon Ferreira de. Evaluating meta-feature selection for the algorithm recommendation problem. **CoRR**, abs/2106.03954, 2021. Disponível em: https://arxiv.org/abs/2106.03954.

QUINLAN, J. R. Induction of decision trees. **Machine Learning**, v. 1, n. 1, p. 81–106, 1986.

RAMAMURTHY, K. N.; VARSHNEY, K. R.; MODY, K. **Topological Data Analysis of Decision Boundaries with Application to Model Selection**. 2018. Disponível em: https://arxiv.org/abs/1805.09949.

REIF, M.; SHAFAIT, F.; DENGEL, A. Meta2-features: Providing meta-learners more information. *In*: **Poster and Demo Track of the 35th German Conference on Artificial Intelligence (KI)**. [*S.l.*: *s.n.*], 2012.

SCHOENFELD, B.; SEPPI, K.; GIRAUD-CARRIER, C. Metalearning using structure-rich pipeline representations for improved automl. **International Journal of Data Analysis Techniques and Strategies**, v. 14, n. 1, p. 49–72, 2022. Disponível em: https://www.inderscienceonline.com/doi/abs/10.1504/IJDATS.2022.129174.

SCHOENFELD, B. J. **Metalearning by Exploiting Granular Machine Learning Pipeline Metadata**. 2020. Dissertação (Mestrado) — Brigham Young University, 2020. Disponível em: https://scholarsarchive.byu.edu/etd/8730/.

SENER, O.; SAVARESE, S. Active learning for convolutional neural networks: A core-set approach. *In*: **International Conference on Learning Representations (ICLR)**. [*S.l.*: *s.n.*], 2018.

SETTLES, B. **Active Learning Literature Survey**. [*S.l.*], 2009. Disponível em: https://minds.wisconsin.edu/bitstream/handle/1793/60660/TR1648.pdf?sequence=1&isAllowed=y.

SPEARMAN, C. The proof and measurement of association between two things. **The American Journal of Psychology**, v. 15, n. 1, p. 72–101, 1904.

TRIANTAFILLOU, E. *et al.* Meta-dataset: A dataset of datasets for learning to learn from few examples. *In*: **International Conference on Learning Representations (ICLR)**. [*s.n.*], 2020. Disponível em: https://arxiv.org/abs/1903.03096.

VANSCHOREN, J. Meta-learning: A survey. **arXiv preprint arXiv:1810.03548**, 2018. Disponível em: https://arxiv.org/abs/1810.03548.

VANSCHOREN, J. *et al.* Openml: Networked science in machine learning. **ACM SIGKDD Explorations Newsletter**, v. 15, n. 2, p. 49–60, 2014. Disponível em: https://www.kdd.org/exploration_files/15-2-2013-12.pdf#page=51.

VARSHNEY, K. R.; RAMAMURTHY, K. N. Persistent topology of decision boundaries. **ICASSP**, IEEE, p. 3931–3935, 2015.

VILALTA, R.; DRISSI, Y. A perspective view and survey of meta-learning. **Artificial Intelligence Review**, v. 18, p. 77–95, 2002.

WANG, G.; SONG, Q.; ZHU, X. **Ensemble Learning Based Classification Algorithm Recommendation**. 2021. Disponível em: https://arxiv.org/abs/2101.05993.

WISTUBA, M.; SCHILLING, N.; SCHMIDT-THIEME, L. Two-stage transfer surrogate model for automatic hyperparameter optimization. *In*: **Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECML/PKDD)**. [*S.l.*: *s.n.*], 2016. p. 13–28.

WOLPERT, D. H.; MACREADY, W. G. No free lunch theorems for optimization. **IEEE Transactions on Evolutionary Computation**, v. 1, n. 1, p. 67–82, 1997.